

CAST

AI 예측 기반 탄소 인지 클라우드 작업 배치 시스템

Carbon-Aware Spatio-Temporal Scheduler

클라우드 작업을 탄소집약도가 낮은 리전과 시간대에 배치하는 스케줄링 시스템

강동규 강희진 김현정 이종하

작품 개요



개발 배경

- AI 반도체 수요 급증으로 데이터센터 전력 수요 폭증
2030년 945TWh 전망 (2024년의 두 배 이상) – IEA [1]
- 발전원 구성이 지역·시간대별로 달라지며 탄소배출량도 함께 변동
하나의 데이터센터가 같은 작업을 해도 실행 지역·시각에 따라 배출량이 크게 달라짐
2025년 실측: 지역 간 최대 수십 배(프랑스 14 vs 인도 543 gCO₂/kWh, 약 39배)
동일 지역(독일) 내에서도 하루 중 최대 2배 이상 변동 [2]
- 데이터센터 에너지 소비·지속가능성 공시 의무화 (EU EED 2024 시행)
- 기존 클라우드 스케줄러(Kubernetes 등)는
실행 완료 시간·자원 효율 중심으로 설계되어 있을 뿐 탄소집약도는 반영하지 않음
이 공백을 메우려는 Google CICS [3], CASPER [4] 등 탄소 인지 배치 연구가 활발히 진행 중

문제 정의

탄소집약도는 시시각각·지역별로 변하지만,
기존 스케줄러는
'언제·어디서 실행해야 탄소가 적은지'는 고려하지 않는다

리전별 탄소집약도 – 2025년 실측 (하루, 1시간 해상도)



CASPER
arXiv 2403.14792 [4]



On the Limitations of
Carbon-Aware Shifting
arXiv 2306.06502 [5]

[1] IEA, "Energy and AI" (April 2025) [2] 탄소집약도 실측: Electricity Maps (2025년 3월 3일, 1시간 해상도)

[3] Google CICS – Radovanović et al., Carbon-Aware Computing for Datacenters (arXiv 2106.11750) [4] Souza et al., CASPER (arXiv 2403.14792)

[5] On the Limitations of Carbon-Aware Temporal and Spatial Workload Shifting in the Cloud (arXiv 2306.06502)

목표 시스템

클라우드 작업을 탄소집약도가 낮은 리전과 시간대에 배치하는 스케줄링 시스템

탄소집약도 예측 · 탄소 인지 로드밸런서 · 탄소 인지 스케줄러

설계 원칙

1. 탄소-지연 가중치(α) 자동 결정

α 수동 설정 없음 — 로드밸런서는 시간대별
파레토 무릎점, 스케줄러는 지연민감도(k) 공식

CASPER [1] · VMware carbon-aware GSLB [2]

2. SLO 보장형 시간 이동

마감 이내의 시각만 탐색 후보로 삼아
마감 초과가 구조적으로 불가능

CASPER [1]


3. 예측 기반 결정, 실측 기반 평가

결정은 LSTM 예측값, 배출량 계산은 실측값
— 예측 오차까지 결과에 반영

Sukprasert et al., EuroSys 2024 [3]

[1] Souza et al., CASPER: Carbon-Aware Scheduling and Provisioning for Distributed Web Services, arXiv:2403.14792 · [2] Maji et al., Bringing Carbon Awareness to Multi-cloud Application Delivery
[3] Sukprasert et al., On the Limitations of Carbon-Aware Temporal and Spatial Workload Shifting in the Cloud, EuroSys 2024

전체 아키텍처




→ 작업별 실행 리전, 실행 시각 결정 (배출 탄소량 · 평균 지연 · SLO 위반율 산출)

모델링 가정

- 작업당 소비전력량 1kWh로 통일
- 작업 데이터는 Alibaba Cluster Trace 분포 기반 합성 — 유형 5종, 주야 도착 비율 7:3
- 리전 간 데이터 전송 지연은 배제 (네트워크 혼잡 미반영, 탄소 최적화에 집중)
- 노드 용량 여유율 0.8 적용 (특정 리전 쏠림 완화)

LSTM 기반 탄소집약도 예측 – 스케줄링 의사결정의 근거



입력 피처


- 전력 - 탄소집약도, 무탄소·재생 에너지 비율
- 시간 - sin/cos(시각·요일·월), 공휴일 여부
- 기상 - 풍속, 일사량, 기온

데이터 분할



- 시간 순서 유지 분할 (셔플 없음)
- 스케일러는 Train으로만 fit (데이터 누수 차단)
- Rolling-Forecast 평가 (배포 환경 재현)

한국 — 실측 vs 1시간 선행 예측 (2025-12-01 ~ 07)



개발 세부 ②

탄소 인지 로드밸런서 — 파레토 무릎점으로 탄소-지연 가중치(α) 결정


- 매시간, 제출된 작업의 특성을 반영해 ILP(정수 선형 계획법)로 리전 배정

$$\text{"min } \sum \alpha \cdot \text{탄소} + (1-\alpha) \cdot \text{지연"} \quad \alpha \in [0,1], \Delta\alpha=0.1$$

- α 는 매시간 파레토 무릎점으로 자동 결정


α 증가에 따른 지연시간과 배출량을 비교해,
정규화 후 이상점(지연·배출 zero)과 가까운 α 를 채택

매시간 자동 결정된 α — 1월 20~23일



탄소집약도 격차가 큰 시간엔 $\alpha \uparrow$, 없는 시간엔 $\alpha \downarrow$ — 옮길 가치가 있을 때만 이동

1년 실측 — 고정 α 5종 vs 자동(무릎점)



탄소 56.9% 절감 · 평균 지연 36.2ms · 드롭 0


탄소 인지 스케줄러 – 최대 허용 지연 안에서 실행시각 결정

$$i^* = \arg \min_i [\beta \cdot \text{정규화 탄소비용}(i) + (1 - \beta) \cdot \text{정규화 지연비용}(i)]$$



- 로드밸런서가 정한 리전 안에서 '언제 실행할지' 결정
- 작업별 지연민감도 k(1~5) → 최대 허용 지연 L_max (1초 ~ 24시간)
- 마감 안의 시각만 고려 → SLO 위반 zero (설계 원칙 2)

지연민감도	작업 유형	가중치	최대 허용 지연(L_max)
k=5	결제 · API 응답	$\beta=0.2$	사실상 즉시 실행(1s)
k=4	사용자 요청·조회	$\beta=0.4$	짧은 지연만 허용(30s)
k=3	알림 · 상태 갱신	$\beta=0.6$	몇 분 내 깨끗한 시각(5m)
k=2	배치 집계·리포트	$\beta=0.8$	수 시간 내 처리(6h)
k=1	로그 · 모델 학습	$\beta=1.0$	하루 내 처리(24h)

요청◆ 대기 — 실행 · 빨강=현재 (그 날 0~24시 UTC)



모듈 통합



현재 시각(UTC)		실행 중인 작업			이 시점 절감	
2026-01-08 18:00		5개			1,163 gCO ₂	
job_id	task_type	출발지	도착지	요청시각	실행시각	누적 절감량
j_128105	로그·모델 학습	Japan	US West (California)	01-08 02:54	01-08 17:54	569
j_000378	로그·모델 학습	US West (California)	US West (California)	01-08 12:11	01-08 17:11	337
j_000368	로그·모델 학습	US West (California)	US West (California)	01-08 12:34	01-08 17:34	233
j_000365	로그·모델 학습	US West (California)	US West (California)	01-08 03:59	01-08 17:59	24
j_091612	로그·모델 학습	Korea	US West (California)	01-08 17:31	01-08 17:31	0

구현 결과

성능 테스트 결과

총 탄소 배출

29,155 → 10,033 kg
공간 -56.8% · 시간 -20.3%

-65.6%

지연 평균

평균 네트워크 지연
시간 지연은 전체 평균 2.1h


36.2 ms

SLO 위반 · 드롭

146,000개 전량 마감 내 처리


0

절감은 두 단계로 누적 — 공간 이동 + 시간 이동



구현 결과

시연



기대효과 및 활용 방안

기대효과 및 활용 방안

- 탄소 규제 정책 대응

데이터센터·클라우드 사업자: 예측 모듈 독립 제공으로 기존 스케줄러 연동 가능
클라우드 사용 기업: 하드웨어 교체 없이 정책만으로 탄소 배출 감소

- 학술적 기여: 시공간 통합 구조 제안

탄소집약도 예측으로 실행 리전과 실행 시각을 동시 고려
(기존 연구는 공간·시간 중 한 축에 집중)

향후 과제

- 실시간 API 연동

현재 시스템은 사전 수집된 이력 데이터로 학습·평가하는 오프라인 구조
Electricity Maps API, Open-Meteo API

- 자동 재학습 파이프라인

인도 2025년 석탄 -3%·태양광 +44% 발전 비율 변화로 예측 오차 3배 증가
월 단위 재학습과 성능 검증 후 배포 (약 5만 파라미터, 재학습 비용 낮음)

- 적용 대상 일반화

시공간 이동 프레임워크를 EV 충전·ESS 디스패치·산업 수요반응 등
이동 가능한 다른 탄소 배출원으로 확장

- 데이터 주권 규제 (GDPR) 대응

"클라우드 작업을 탄소집약도가 낮은 리전과 시간대에 배치한다"