

CAST: 리전 용량 제약을 고려한 탄소 인지 시공간 워크로드 스케줄링

CAST: Carbon-Aware Spatio-Temporal Scheduling

초록 데이터센터의 탄소 배출량은 같은 작업이라도 어느 리전에서 언제 실행하느냐에 따라 크게 달라진다. 본 연구는 미래 탄소집약도를 LSTM 으로 예측하고, 정수계획법으로 작업을 저탄소 리전에 배정한 뒤, 마감 시간 안에서 시간을 옮겨 배출량을 한 번 더 줄이는 CAST 를 제안한다. 탄소와 지연 사이의 가중치는 고정하지 않고, 매 시간 슬롯마다 파레토 곡선의 무릎점에서 자동으로 정한다. 8 개 리전, 1 년치 실측 탄소 데이터 위에서 돌린 합성 작업 146,000 건으로 실험한 결과, 시간 이동만으로 18.60%, 리전 이동만으로 56.85%를 줄였고 둘을 결합하면 63.03%를 줄였으며 마감 위반은 없었다. 무릎점 자동 선택은 가중치 고정($\alpha=0.5$) 대비 지연 6.7ms 만 더 쓰고 탄소는 10.64%포인트 더 줄인다. 리전별 용량 상한은 온라인으로 강제하며, 어떤 작업도 무한히 밀리지 않음을 증명한다. 그 대가로 시간 이동의 뚝은 9.07%포인트에서 6.18%포인트로 준다.

주제어: 탄소 인지 스케줄링, 워크로드 이동, 정수 계획법, 리전 용량, LSTM

Abstract The carbon footprint of a cloud workload varies substantially depending on which region and when it runs. We present CAST, a carbon-aware scheduler that forecasts future carbon intensity with an LSTM, places jobs across regions via integer programming, and further shifts them in time within each job's deadline. Rather than fixing the trade-off between carbon and latency, CAST selects it automatically at every time slot by locating the knee point of the Pareto curve. Evaluated on 146,000 synthetic jobs driven by one year of measured carbon-intensity data across 8 regions, temporal shifting alone reduces emissions by 18.60%, spatial placement alone by 56.85%, and combining both reduces emissions by 63.03% with zero deadline violations. The automatic knee-point weight cuts 10.64 percentage points more carbon than a fixed weight ($\alpha=0.5$), at the cost of only 6.7ms additional latency. CAST enforces per-region capacity limits online and we prove that no job is deferred indefinitely. The cost of this enforcement is quantified: temporal shifting's marginal contribution shrinks from an unconstrained upper bound of 9.07 percentage points to 6.18 percentage points.

Keywords: Carbon-aware scheduling, Workload shifting, Integer programming, Regional capacity, LSTM

이종하¹ · 강희진¹ · 강동규¹ · 김현정¹ · 남재현^{1*}

¹ 단국대학교

* Corresponding Author: 남재현 (E-mail: njh@example.com, 임시 — 확정 필요)

강희진 (E-mail: heejin@example.com, 임시 — 확정 필요)

접수일: [YYYY-MM-DD] / 수정일: [YYYY-MM-DD] / 게재확정일: [YYYY-MM-DD]

1. 서론

데이터센터가 소비하는 전력이 빠르게 늘고 있다. 국제에너지기구는 2024 년 약 415TWh 였던 전 세계 데이터센터 전력 소비가 2030 년 945TWh 에 이를 것으로 전망했으며, AI 를 가장 큰 요인으로 지목했다.

<https://www.iea.org/reports/energy-and-ai/executive-summary>
— 원문: "Data centre electricity consumption is set to more than double to around 945 TWh by 2030... AI is the most important driver of this growth"

EU 는 개정 에너지효율지침 제 12 조와 이를 구체화한 위임 규정을 통해 IT 전력 수요 500kW 이상 데이터센터에 에너지 성능 지표를 EU 공동 데이터베이스에 보고하도록 의무화했다.
<https://eur-lex.europa.eu/legal-content/EN/TXT/HTML/?uri=CELEX:32023L1791>

에너지 사용의 투명성이 규제 대상이 된 이상, 소비 전력과 그에 따른 탄소 배출을 줄이는 일은 운영상의 과제가 되었다.

통상적인 대응은 설비 효율 개선과 저탄소 전원 조달이다. 그러나 두 방법 모두 수요 증가 속도를 따라잡기 어렵다. IEA 는 효율 개선을 크게 가정한 High Efficiency Case 에서도 2035 년 데이터센터 전력 수요가 Base Case 대비 20% 낮아지는 데 그친다고 분석했다.

<https://www.iea.org/reports/energy-and-ai/executive-summary>
— 원문: "In this case, electricity demand from data centres is 20% lower in 2035 than in the Base Case."

저탄소 전원 조달 역시 완전한 해법은 아니다. IEA Base Case 에서 데이터센터 전력 사용에 따른

배출량은 2035 년 연 3 억 톤까지 늘어난다. 재생에너지 조달이 통상 연간 소비량 단위로 이루어져 시간별 격차를 해소하지 못하는 데다, 신규 송전선 건설에 4~8 년이 걸리는 전력망 자체도 제약이기 때문이다. <https://www.iea.org/reports/energy-and-ai/executive-summary>

— 원문: "Half of the global growth in data centre demand is met by renewables" / "Natural gas expands by 175 TWh" / "Nuclear contributes about the same amount of additional generation" / "grows from 180 million tonnes (Mt) today to 300 Mt in the Base Case by 2035" / "these emissions remain below 1.5% of the total energy sector emissions in this period, data centres are among the fastest growing sources of emissions"

<https://www.gstatic.com/gumdrop/sustainability/24x7-carbon-free-energy-methodologies-metrics.pdf>
— Google, "24/7 Carbon-Free Energy: Methodologies and Metrics," 2021

— 원문: "The carbon footprint of our electricity consumption varies hourly, depending on the mix of electricity generation sources operating in a particular hour"
— 원문: "a company that purchases renewable electricity... in an amount equivalent to their annual consumption within the same market can claim that their electricity consumption resulted in zero emissions in that market"

<https://www.iea.org/reports/energy-and-ai/executive-summary>
— 원문: "around 20% of planned data centre projects could be at risk of delays" / "Building new transmission lines can take four to eight years" / "wait times for critical grid components such as transformers and cables have doubled in the past three years"

따라서 이미 가동 중인 인프라를 대상으로, 신규 설비 투자 없이 단기간에 적용 가능한 감축 수단이 별도로 필요하다.

그러나 배출량을 결정하는 것은 소비 전력량만이 아니다. 전력 1kWh 를 생산할 때 배출되는 탄소량, 즉 탄소집약도는 그 순간 전력망의 발전원 구성에 따라 정해진다. 화석연료 기반 발전은 탄소 가중치가 높고 재생에너지와 원자력은 낮거나 0 이므로, 발전

믹스의 구성 비율이 곧 탄소집약도가 된다.

<https://doi.org/10.1145/3634769.3634812>

이 값은 지역에 따라, 그리고 같은 지역 안에서도 시각에 따라 달라진다. 선행 연구는 2022 년 여섯 개 클라우드 리전에서 약 6 배의 공간적 격차를 관측했으며, 시간적으로도 프랑스에서 연간 4 배, 독일과 캘리포니아에서 6~8 배의 변동을 보고했다.

<https://doi.org/10.1145/3634769.3634812>

— 원문: "6× spatial variations" / "4× variation over a year in France, and an even higher 6-8× variation in Germany and California"

본 연구가 대상으로 삼은 8 개 리전에서도 유사한 규모의 격차가 관측되었다.

2025 년 실측 기준 연평균 탄소집약도는 인도가 544.1 gCO₂/kWh, 프랑스가 13.6 gCO₂/kWh 로 39.9 배의 공간적 격차를 보인다. 시간적으로는 리전 내 하루 최댓값과 최솟값의 비가 캘리포니아 3.53 배, 독일 2.39 배, 프랑스 2.33 배, 텍사스 1.77 배로 나타나며, 한국 1.17 배와 뉴욕 1.15 배처럼 변동이 작은 리전도 있다.

즉 동일한 작업이라도 어느 리전에서 언제 실행하느냐에 따라 배출량이 달라진다. 선행 연구는 실행 시점의 탄소집약도에 따라 배출량이 최대 40%, 실행 리전에 따라서는 최대 6~8 배까지 차이 날 수 있다고 지적했다.

<https://doi.org/10.1145/3634769.3634812>

— 원문: "the carbon footprint of a job can vary by up to 40% depending on whether it is executed during a high or low carbon-intensity period" — 원문: "executing the same job in different cloud regions can lead to a 6-8x variation in emissions"

이 차이를 활용할 조건은 이미 갖추어져 있다. 클라우드 서비스는 다수 리전에 분산 배치되어 있으며, AI 모델 학습이나 로그 처리 같은 배치성 작업은 완료 시점에 유연성이 있어 시간 이동이 가능하다.

<https://doi.org/10.1145/3634769.3634812>

— 원문: "batch jobs such as AI and machine learning often have flexible completion times and can accommodate temporal variations"

두 축의 결합 효과는 공간 이동의 목적지가 어디로 정해지는지에 달려 있다. 공간 이동의 이득은 목적지 리전의 평균 탄소집약도가, 시간 이동의 이득은 그 리전에 남은 변동 폭이 결정하기 때문이다. 본 논문은 리전별 용량이 유한한 조건에서 이 조합이 어떻게 달라지는지 검증한다.

시스템 구현 연구는 대체로 두 축 중 하나에 집중해 왔고, 두 축을 함께 다룬 분석 연구는 특정 가정 아래 결론을 내렸다. 선행 문헌 검토는 28 편의 관련 연구 가운데 공간과 시간을 함께 고려한 것이 11 편이며, 그중 결합 최적화 알고리즘을 제시한 것은 2 편에 그친다고 보고한다. <https://doi.org/10.3390/su17146433> —

Asadov, Coroamă, Franzil, Galantino, Finkbeiner, Sustainability 17(14):6433, 2025 — 원문: "We present a literature review of carbon-aware scheduling techniques, which shows that most of the literature carried out either spatial or temporal shifting but not both. Of the 28 analyzed studies, 11 considered both spatial and temporal shifting, and only 2 developed a combined optimization algorithm."

시간 축에서는 구글의 CICS 가, 공간 축에서는 CASPER 와 VMware GSLB 가 대표적이다. 이들 시스템은 두 축 중 하나에 한정될 뿐 아니라, 탄소와 그 밖의 목적 사이의 가중치를 고정 상수로 둔다. 그러나 리전 간 탄소집약도 격차는 시각에 따라 변하므로, 옮길 이득이 큰 시간과 그렇지 않은 시간에 동일한 가중치를 적용하는 것은 최적이라 보기 어렵다.

<https://arxiv.org/pdf/2106.11750>

— 원문: "generate the next day's carbon-aware Virtual Capacity Curves (VCCs) for all datacenter clusters across Google's fleet"

— 원문: "we demonstrate a power consumption drop of 1-2% at times with the highest carbon intensity"

— 원문: "which shifts datacenter computing in time and will soon also shift computing in space"

<https://doi.org/10.1145/3634769.3634812>

— 원문: "we focus on exploiting spatial characteristics that involves distributing workloads across regions with both low carbon intensity and sufficient latency performance"

<https://dl.acm.org/doi/10.1145/3604930.3605711>

<https://doi.org/10.1145/3634769.3634812>

— 원문: " $\alpha = 0.5$ (equal weights)" / "results would change with other α values"

<https://arxiv.org/pdf/2106.11750>

— 원문: "The optimization outcome changes depending on the desired tradeoffs between carbon footprint and efficiency"

두 축을 함께 다룬 Sukprasert 등의 상한 분석은 공간 이동의 절감이 지배적이고 시간 이동의 추가 이득은 제한적이라고 결론지었다. 같은 연구는 전 리전이 50%가동률일 때 공간 이동 절감이 이상적 조건 대비 1.9배 감소한다는 점을 보여 용량이 결정적 변수임을 확인했음에도, 정작 두 축을 결합한 분석에서는 용량 제약을 두지 않았다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "savings from spatial migration dominate the overall savings, with limited additional benefits from performing temporal shifting"

— 원문: "For a mean utilization of 50%, the global average carbon reductions drop to 51.5%, a 1.9× decrease when compared to our ideal case"

— 원문: "carbon-intensity traces for 123 different geographical regions worldwide from 2020 to 2022 using the Electricity Maps web API"

용량이 시간 이동의 뭉에 미치는 영향은 뚜렷하다. 리전 용량을 좁힐수록(피크 대비 0.5 배까지) 시간 이동의 기여는 무제한일 때의 8.95%포인트에서 1.20%포인트로 줄어든다(\$6.5, 표 5). 용량이 좁을수록 배치가 끝난 뒤 남은 여지 자체가 줄어, 시간 이동이 활용할 수 있는 뭉도 함께 줄기 때문이다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "there are some exceptions where regions have low spatial gains and high temporal gains and yet result in relatively high net carbon reductions, such as California (US-CA) and Virginia (US-VA)"

클러스터 용량 제약을 명시적으로 다룬 CarbonFlex 는 단일 클러스터 내 시간 이동에 한정되어 리전 간 공간 이동을 다루지 않는다.

<https://arxiv.org/abs/2505.18357>

— 원문: "clusters have a capacity limit that prior work on optimizing individual jobs in the cloud does not consider."

— 원문: "Considering a capacity limit is important to avoid a 'thundering herd' problem where all jobs defer their execution to the same low-carbon time and potentially exceed the cluster's capacity."

본 논문은 리전별 용량이 유한하고 여유율 제약이 존재하는 조건에서 공간과 시간 이동을 결합하여, 두 축의 결합 효과를 재검토한다.

본 논문은 탄소 인지 스케줄링 시스템 CAST 를 제안한다. CAST 는 LSTM(Long Short-Term Memory, 장단기 기억 신경망)으로 8 개 리전의 향후 24 시간 탄소집약도를 예측하고, 정수 선형 계획법 기반 로드밸런서가 실행 리전을 결정한 뒤, 스케줄러가 각 작업의 마감 이내에서 실행 시각을 결정한다.

기여는 다음 네 가지다.

첫째, 공간 축의 탄소-지연 가중치를 매 슬롯 파레토 무류점으로 자동 결정하고, 시간 축의 가중치는 작업이 신고한 지연 등급의 함수로 정의한다.

둘째, 공간 이동과 시간 이동을 단일 파이프라인으로 결합하고, 두 축의 절감 효과가 누적됨을 1 년치 실측 데이터로 확인했다.

셋째, 시간 이동 단계가 리전 용량을 고려하지 않을 때 프랑스와 캘리포니아에서 동시 실행 수가 여유율 상한의 3.4 배인 41 건에 이르고, 연중 각각 622 시간과 867 시간 동안 상한을 초과함을 실측한 뒤, 이를 온라인으로 강제하는 알고리즘(Algorithm 1)을 제시한다. 이 알고리즘은 슬롯마다 리전 점유량을 추적하여 상한에 도달한 슬롯을 후보에서 제외하며, 어떤 작업도 무한히 연기되지 않고 마감 위반이 발생하지 않음을 증명한다. 선행 연구는 이 현상을 단일 클러스터 맥락에서 지적하였으나 정량화하지 않았고, 리전 간 이동과 결합한 온라인 강제 기법도 제시하지 않았다.

<https://arxiv.org/abs/2505.18357> — 원문: "Considering a capacity

limit is important to avoid a 'thundering herd' problem where all jobs defer their execution to the same low-carbon time and potentially exceed the cluster's capacity."

넷째, 배치 결정은 예측값으로 수행하되 배출량 산정은 실측값으로 하여, 예측 오차의 대가가 결과에 반영되도록 했다.

1 년치 실측 탄소집약도 데이터를 사용한 시뮬레이션에서 총 배출량이 63.03% 감소하였다. 공간 이동과 온라인 용량 인지 시간 이동을 결합한 결과로, 작업 146,000 건 전량이 마감 이내에 처리되어 마감 위반은 발생하지 않았다.

2. 배경 지식

2.1 탄소집약도의 시공간적 특성

CAST 는 8 개 리전을 대상으로 한다. 미국 3 개(캘리포니아, 텍사스, 뉴욕), 유럽 2 개(프랑스, 독일), 아시아 3 개(한국, 일본, 인도)로, 발전원 구성이 상이하고 미주·유럽·아시아 세 시간대 그룹에 걸치도록 선정하였다. 한국과 일본, 프랑스와 독일은 각각 동일한 표준시를 공유하므로 일주기의 위상이 정렬되어 있어, 동일 시각에서의 공간 격차를 직접 비교할 수 있는 쌍으로 기능한다. 탄소집약도 실측값은 Electricity Maps API 를 통해 1 시간 해상도로 수집하였다.

<https://www.electricitymaps.com/data-portal>

인도는 석탄 화력 의존도가 높아 종일 높은 수준을 유지하는 반면, 프랑스는 원자력이 기저 부하를 담당하여 종일 낮고 평탄하다. 캘리포니아와 독일은 낮 시간대 태양광 발전이 유입되며 값이 크게 하락한 뒤 일몰 이후 회복되는 형태를 보인다.

이러한 관측은 선행 연구와 일치한다. Sukprasert 등은 123 개 리전을 분석하여 지역 간 43 배 이상의

격차와 2022 년 평균 탄소집약도 기준 40 배의 차이를 보고하였으며, 화석연료 기반 계통일수록 평균 탄소집약도가 높고 변동성은 낮다는 경향도 함께 관측하였다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "can vary by 2× over a day (in California) and by over 43× across regions (between Ontario and Mumbai)"

— 원문(\$4.1): "there is a 40× difference in average CI between the highest and lowest regions"

— 원문: "grids that derive electricity from such sources exhibit low variations in carbon-intensity. Conversely, grids with higher fractions of intermittent sources, such as wind and solar, exhibit higher variations"

2.2 클라우드 작업의 지연 허용도

클라우드 작업은 지연 허용도에 따라 두 부류로 나뉜다. 데이터 처리, 기계학습 학습, 시뮬레이션 등 배치성 작업은 처리량을 중시하고 엄격한 지연 요구가 없어 실행 시점을 미루거나 중단·재개할 수 있다. 반면 웹 요청이나 추론 요청과 같은 대화형 작업은 즉시 응답해야 하므로 시간 유연성이 없으나, 다른 데이터센터로 라우팅하는 공간 유연성은 갖는다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "batch and interactive – each with its own dimensions and degrees of spatiotemporal flexibility"

— 원문: "While such requests cannot be delayed and have no temporal flexibility, they can often be flexibly routed to different datacenters"

이러한 구분은 이미 실무 스케줄러에 반영되어 있다. Borg, 쿠버네티스, Slurm 은 우선순위가 높은 요청을 처리하기 위해 배치 작업을 지연시키거나 중단한다. 다만 이는 우선순위 기반 선점 기제이며, 작업별 최대 허용 지연을 명시하는 것과는 다르다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "Cluster schedulers, such as Google's Borg, Kubernetes, and Slurm, often defer or interrupt batch jobs to satisfy higher-priority requests"

— 원문: "we vary our slack from 24 hours to a year"

2.3 탄소집약도의 예측 가능성

시간 이동이 성립하려면 미래 시점의 탄소집약도를 알아야 한다. Sukprasert 등이 하이퍼스케일 데이터센터가 위치한 40 개 리전을 분석한 결과,

35 개(87%)가 24 시간 주기를 0.5 이상의 주기성 점수로 나타냈고 상당수는 주간 주기도 함께 보였다. 그러나 예측 가능성과 절감 잠재력은 별개다. 같은 연구는 전 세계 70% 이상의 리전이 일간 변동성이 낮으며, 이는 화석연료·수력·원자력 의존에 기인한다고 밝혔다. 이들 발전원은 변동성이 작아 다수 리전에서 시간 이동의 이득을 제한한다. 24시간 여유를 가정한 경우 시간 이동 단독의 전 지구 평균 절감은 31 gCO₂eq 로, 전 지구 평균 탄소집약도 368.39 gCO₂eq/kWh 대비 8.4%에 그친다.

따라서 CAST 는 시간 이동을 단독 감축 수단으로 두지 않는다. 공간 이동을 우선 적용하되, 리전별 용량 제약으로 공간 이동이 포화된 구간에서 시간 이동을 보완적으로 적용하는 구조를 취한다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "35 of the 40 regions (87%) exhibit a 24-hour period... with a periodicity score of 0.5 or higher"
— 원문: "more than 70% of regions worldwide have low daily carbon-intensity variations due to their reliance on fossil fuel-based, hydro, or nuclear power generation."
— 원문: "These energy sources have low variability, which limits the benefit of temporal shifting in many cloud regions."
— 원문: "the carbon reductions vary from 31 g·CO₂eq to 127 g·CO₂eq, 8.4% and 34% relative to the average global emissions"
— 원문 각주: 낮은 일간 변동성은 변동계수(CV) 0.1 미만으로 정의됨

탄소집약도 예측은 독립된 연구 주제이기도 하다. DACF 는 발전원별 생산량을 인공지능망으로 예측한 뒤 배출계수를 적용해 향후 24 시간의 탄소집약도를 산출하며, 미국·유럽 6 개 리전에서 평균 MAPE 6.4%를 보고하였다. 다만 DACF 가 쓰는 IPCC AR5 직접 배출계수와 본 연구가 쓰는 Electricity Maps 의 전과정 배출계수는 수준과 변동 폭이 모두 달라 수치를 그대로 견주기는 어렵다.

<https://doi.org/10.1145/3538637.3538849>

— Maji, Sitaraman, Shenoy, "DACF," ACM e-Energy '22
— 원문: "DACF has a mean MAPE of 6.4% across the regions"
— 원문(Table 4): CA 7.41 / PJM 3.30 / TX 8.05 / NE 4.44 / SE 6.47 / DE 9.08
— 원문: "we follow the median carbon-emission rate due to direct emissions that only include operational emissions"

— 원문: "We use the predictions of the last six months of 2021 for testing"

— 원문(Table 3): 태양광·풍력 예보는 CA 만 OASIS 사용, PJM·TX·NE 는 N/A

<https://doi.org/10.1145/3563357.3564079>

— Maji, Shenoy, Sitaraman, "CarbonCast," BuildSys '22, pp. 198–207

— 원문: "uses neural networks to first generate production forecasts for all the electricity-generating sources. It then uses a hybrid CNN-LSTM approach to combine these first-tier forecasts with historical carbon intensity data and weather forecasts"
— 원문: "MAPE of 4.80–13.93% across six geographically distributed regions"

<https://doi.org/10.1145/3607114.3607117>

— 확장판: ACM SIGENERGY Energy Informatics Review 3(2):19–33, 2023

— 원문: "3.42–19.95% across 13 geographically distributed regions"

<https://www.electricitymaps.com/data/methodology>

— Electricity Maps 배출계수 체계.

CAST 는 과거 168 시간의 계통·시간·기상 정보와 향후 24 시간 기상 예보를 입력으로 하는 리전별 단일 LSTM 모델을 사용한다. 구조와 성능은 각각 뒤에서 기술한다.

탄소 배출량을 최소화하는 것이 본 연구가 다루는 문제다. 단 각 작업은 자신에게 허용된 지연 범위 안에서 완료되어야 하고, 각 리전은 유한한 처리 용량을 갖는다.

배출량은 작업이 소비한 전력량과 실행 시점·실행 리전의 탄소집약도의 곱으로 정해진다. 소비 전력량이 고정되어 있다면 남은 결정 변수는 실행 리전과 실행 시각 두 가지다. 따라서 이 문제는 배치 결정을 통해 각 작업이 마주하는 탄소집약도를 낮추는 문제로 환원된다.

3.2 제약 조건

세 가지 제약이 동시에 작용한다.

첫째, 지연 제약이다. 작업을 더 깨끗한 리전으로 보내면 네트워크 왕복 지연이 늘고, 더 깨끗한 시각으로 미루면 완료가 늦어진다. 두 지연의 합은 작업이 신고한 허용치를 넘을 수 없다.

둘째, 용량 제약이다. 가장 깨끗한 리전으로 모든 작업을 보낼 수는 없다. 리전마다 동시에 처리할 수 있는 작업 수가 정해져 있으며, 이 제약이 없으면 저탄소 시각이나 저탄소 리전에 부하가 집중되는 현상이 발생한다. 선행 연구는 개별 작업 단위 최적화가 이 제약을 고려하지 않을 때 모든 작업이 동일한 저탄소 시각으로 실행을 미루는 문제가 나타난다고 지적하였다.

<https://arxiv.org/abs/2505.18357>

— 원문: "Considering a capacity limit is important to avoid a 'thundering herd' problem where all jobs defer their execution to the same low-carbon time and potentially exceed the cluster's capacity."

셋째, 예측 제약이다. 실행 시각을 지금 결정하려면 아직 오지 않은 시각의 탄소집약도를 알아야 한다. 이는 관측이 아니라 예측의 문제이며, 예측이 빗나가면 의도했던 것보다 높은 탄소집약도에서 작업이 실행된다.

3.3 결정의 구조

3. 풀고자 하는 문제

3.1 문제 정의

클라우드에 제출된 작업 집합이 주어졌을 때, 각 작업을 어느 리전에서 언제 실행할지 결정하여 총

이 문제가 단순한 최소화가 아닌 이유는 목적이 하나가 아니기 때문이다. 탄소를 줄이려면 지연을 내주어야 하고, 지연을 줄이려면 탄소를 감수해야 한다. 두 목적 사이에는 단일한 최적해가 존재하지 않으며, 어느 지점을 택할지에 대한 기준이 별도로 필요하다.

선행 연구는 이 기준을 상수로 고정한다. 그 한계는 4.4 절에서 다룬다. 이 기준을 어떻게 정할 것인가가 본 연구가 다루는 두 번째 문제다.

세 번째 문제는 평가에 관한 것이다. 배치를 예측값으로 결정했다면, 그 결정의 결과인 배출량은 실제로 발생한 값으로 산정되어야 한다. 예측값으로 결정하고 예측값으로 채점하면 예측 오차의 대가가 결과에서 사라진다.

3.4 범위

본 연구가 다루는 것과 다루지 않는 것을 명확히 한다.

대상 작업은 지연 허용치를 명시할 수 있는 작업으로 한정한다. 실시간 스트리밍처럼 시간·공간 유연성이 모두 없는 작업은 대상이 아니다.

최적화 축은 실행 리전과 실행 시각이다. 하드웨어 효율, 냉각, PUE 개선은 다루지 않는다.

배출 범위는 운영 단계의 전력 소비에 따른 배출로 한정한다. 서버 제조와 폐기 과정에서 발생하는 내재 탄소는 고려하지 않는다.

네트워크는 리전 간 왕복 지연만 반영하고, 리전 간 데이터 전송량과 그에 따른 비용은 반영하지 않는다.

전력 소비가 1~2% 감소했다. 저자들은 결론에서 공간 이동으로의 확장을 예고하였다.

<https://arxiv.org/pdf/2106.11750>

— Radovanović et al., IEEE Trans. Power Systems 38(2):1270–1280, 2023

— 원문: "generate the next day's carbon-aware Virtual Capacity Curves (VCCs) for all datacenter clusters across Google's fleet"

— 원문: "we demonstrate a power consumption drop of 1-2% at times with the highest carbon intensity"

— 원문: "which shifts datacenter computing in time and will soon also shift computing in space"

클러스터 단위 접근으로는 CarbonFlex 가 있다. 클러스터 용량 제약을 명시적으로 다루며, 개별 작업 단위의 선행 연구가 이를 고려하지 않는다는 점과, 용량 제약을 두지 않으면 모든 작업이 동일한 저탄소 시각으로 실행을 이루는 문제가 발생한다는 점을 지적하였다. CPU 클러스터에서 51.4%, GPU 클러스터에서 57.5%의 탄소 절감을 보고한다. 다만 단일 클러스터 내 시간 이동과 자원 탄력성에 한정되며, 리전 간 공간 이동은 다루지 않는다.

<https://arxiv.org/abs/2505.18357>

— Hanafy, Wu, Irwin, Shenoy, arXiv:2505.18357, 2025

— 원문: "clusters have a capacity limit that prior work on optimizing individual jobs in the cloud does not consider."

— 원문: "Considering a capacity limit is important to avoid a 'thundering herd' problem where all jobs defer their execution to the same low-carbon time and potentially exceed the cluster's capacity."

4. 관련 연구와 그 한계

4.1 시간 축 접근

구글의 CICS 는 유연한 배치 작업의 실행 시각을 저탄소 시간대로 이루는 시스템이다. 탄소집약도 예보와 다음날 수요 예측을 결합한 위험 인지 최적화로 클러스터별 시간별 가상 용량 곡선을 산출하고, 이 곡선이 시간별 자원 상한을 정해 실시간 스케줄러가 저탄소 시간대에 더 많은 작업을 수용하도록 유도한다. 구글 전 데이터센터 클러스터를 대상으로 프로덕션 배포되어 있으며, 운영 데이터에서 탄소집약도가 가장 높은 시간대의

4.2 공간 축 접근

CASPER 는 분산 웹 서비스로 들어오는 요청을 탄소집약도가 낮은 리전으로 라우팅한다. 정수 선형 계획법으로 리전별 서버 프로비저닝과 요청 배정을 함께 결정하며, 여섯 개 AWS 리전을 대상으로 쿠버네티스 프로토타입을 구현하였다. 지연 상한을 20ms 에서 500ms 까지 완화하며 실험한 결과 각각 25%와 최대 70%의 탄소 절감을 보고한다. 저자들은 시간적 변동의 활용 가능성을 인정하면서도 본 연구는 공간적 변동의 활용에 집중한다고 명시하였다.

<https://doi.org/10.1145/3634769.3634812>

— Souza et al., IGSC '23, pp. 67–73

— 원문: "we focus on exploiting spatial characteristics that involves distributing workloads across regions with both low carbon intensity and sufficient latency performance"

— 원문: "Carbon-20 demonstrates that even small relaxations in latency constraints can result in a 25% carbon reductions... Carbon-400 reaches a point of diminishing returns with a 70% reduction"

VMware의 Avi GSLB에 탄소 인지 기능을 부여한 연구도 같은 축에 속한다. 기존에 지리적 근접성만으로 요청을 분산하던 로드밸런서에 실시간 탄소집약도를 판단 요소로 추가하여, 평균 21%, 최대 51%의 탄소 감축을 보고하였다.

<https://dl.acm.org/doi/10.1145/3604930.3605711>

— Maji et al., HotCarbon '23, pp. 1–6

— 원문: "Our carbon-aware prototype shows an average of 21% and a maximum of 51% reduction in carbon emissions while operating with an acceptable latency"

4.3 두 축을 함께 다룬 분석

Sukprasert 등은 123 개 리전의 3 년치(2020~2022) 탄소집약도 데이터로 시공간 이동의 상한을 분석하였다. 이상적 조건에서 공간 이동은 전 지구 평균 대비 96%까지 절감할 수 있으나, 전 리전이 50% 가동률이라는 제약만 추가해도 51.5%로 떨어지고, 여기에 50ms 지연 제약까지 걸면 31%까지 낮아진다. 시간 이동은 24 시간 여유 기준 8.4%에 그친다. 두 축을 결합한 경우 공간 이동의 절감이 지배적이며 시간 이동의 추가 이득은 제한적이라고 결론지었다.

<https://doi.org/10.1145/3627703.3650079>

— Sukprasert et al., EuroSys '24, pp. 924–941

— 원문: "savings from spatial migration dominate the overall savings, with limited additional benefits from performing temporal shifting"

— 원문: "For a mean utilization of 50%, the global average carbon reductions drop to 51.5%, a 1.9× decrease when compared to our ideal case"

— 원문: "the average global carbon reductions dropping from 52% to 31% for a 50ms latency constraint and 50% datacenter utilization"

같은 가정과 같은 결론이 2 년 뒤에도 반복된다. Attenni 등은 Azure 와 AWS 의 4~5 개 리전을 대상으로 사계절 각 1 주일 구간에서 공간 이동과 시간 이동을 결합하여 분석하였다. 이 연구는 탄소뿐 아니라 물 사용과 토지 사용까지 목적 축에 포함한다는 점에서 범위가 더 넓다. 예측 오차는 실측 계열에 노이즈를 주입하여 모사하고 그에 대한

민감도 분석을 수행한다. 그림에도 두 축을 결합한 결론은 앞의 연구와 같다. <https://arxiv.org/abs/2512.08725>

— Attenni, Moawad, Bartolini, Thamsen, arXiv:2512.08725, 2025 년 12 월 투고, 2026 년 3 월 개정 — 원문: "When applied together, the two strategies yield the greatest overall reduction, driven mainly by spatial shifting with temporal adjustments providing an additional, incremental benefit." — 원문: "Sensitivity analysis demonstrates that such shifting is robust to prediction errors in grid mix data and to variations across different seasons." 본 연구는 8 개 리전의 1 년 연속 데이터를 사용한다.

Caspian 은 두 축을 하나의 정수 계획법으로 동시에 결정하는 실제 구현이다. 리전과 시간대를 함께 인덱싱하는 결정 변수로 작업 배치를 정하고, 클러스터별 가용 자원을 시간대별 제약으로 명시한다. 허브 1 개와 스포크 3 개로 구성된 실제 쿠버네티스 클러스터에 배포하여 탄소 배출량을 약 33% 줄이면서 작업의 98%가 마감 내에 완료됨을 보였다. 다만 지속가능성 가중치(ω_1)를 높일수록 배출은 더 줄지만 마감을 놓치는 작업도 늘어나는 상충이 나타났고, 저자들 스스로 가중치 값을 정하는 데 상당한 주의가 필요하다고 결론지었다.

<https://doi.org/10.1109/MASCOTS64422.2024.10786568>

— Bahreini, Tantawi, Tardieu, MASCOTS '24 — 원문: "We conclude that great care has to be taken when setting the values of the weights ω_k ."

본 연구의 평가 구성(가중치를 바꿔가며 비교하는 스왑과 단계별 비교)은 Caspian 의 방식을 따르되, 가중치를 사람이 정하는 대신 매 슬롯 파레토 무릎점에서 자동으로 결정한다는 점에서 달라진다.

4.4 기존 연구의 한계

첫째, 두 축이 결합된 조건에서 용량 제약이 검토되지 않았다. Sukprasert 등의 분석에서 용량은 공간 이동의 이득을 크게 좌우하는 변수로 확인되었으나, 정작 두 축을 결합한 분석에서는 용량 제약을 두지 않는다. 이 설정에서는 부하가 저탄소·저변동 리전으로 우선 수용되므로 시간 이동의 여지가 구조적으로 줄어든다.

이는 한 연구에 국한된 현상이 아니다. 2년 뒤 발표된 Attenni 등의 시공간 결합 연구도 자원이 항상 가용하다고 가정하며, 저자들은 이를 타당성 위협 절에서 스스로 밝히고 있다.

<https://arxiv.org/abs/2512.08725> — 원문: "It is assumed that there are always resources available, which might not be true in reality. However, considering the promise of elastic scalability of public cloud providers and general availability of surplus "spot" resources, specifically for the large-scale, elastic, hyperscale infrastructures operated by major providers such as AWS and Azure, this appears to be a sensible assumption."

그러나 이 방어는 두 가지 이유로 뒷받침되지 않는다. 하나는, 탄력적 확장성과 spot 잉여 자원은 클라우드 전체가 집계 수준에서 갖는 성질이지 특정 시각의 특정 리전이 갖는 성질이 아니다. 탄소 인지 스케줄링이 만들어내는 것은 정확히 그 반대, 곧 저탄소 시간대의 특정 리전으로의 수요 집중이다. 즉 이 방어가 전제하는 잉여를, 이 방어가 옹호하는 기법이 스스로 소진시킨다. 다른 하나는, 해당 방어 문장에는 인용이 붙어 있지 않으며 탄력적 확장성과 spot 자원이라는 용어는 그 논문의 다른 어느 곳에도 다시 등장하지 않는다. 본 연구가 검증 절에서 측정한 캘리포니아의 19시부터 21 시까지의 집중이 바로 이 반박이 예측하는 현상이다.

다만 같은 연구는 공간 이득이 낮음에도 높은 시간 변동 덕분에 순 절감이 유의미한 예외로 캘리포니아와 버지니아를 지목하였다. 이는 목적지가 고변동 리전일 때 시간 이동이 실질적으로 기여함을 시사한다. 리전별 용량이 유한하고 여유율 제약으로 공간 이동이 조기에 포화되면 부하가 고변동 리전까지 확산되므로, 이 예외가 일반적 상황이 될 수 있다.

<https://doi.org/10.1145/3627703.3650079>

— 원문: "there are some exceptions where regions have low spatial gains and high temporal gains and yet result in relatively high net carbon reductions, such as California (US-CA) and Virginia (US-VA)"

둘째, 탄소와 그 밖의 목적 사이의 가중치가 고정 상수로 설정된다. CASPER 는 탄소와 서버 프로비저닝 비용 사이의 가중치를 실험 전반에서

0.5로 고정하며, 저자들 스스로 다른 값에서는 요청 재분배 양상과 결과가 달라질 것이라고 밝혔다. CICS 역시 탄소 비용과 피크 전력 인프라 비용의 가중합을 목적함수로 두고, 두 항의 상대적 비중에 따라 최적화 결과가 달라진다고 논한다. 그러나 리전 간 탄소집약도 격차는 시각에 따라 변하므로, 옮겨서 얻는 이득이 큰 시간과 그렇지 않은 시간에 동일한 가중치를 적용하는 것은 최적이라 보기 어렵다.

<https://doi.org/10.1145/3634769.3634812>

— 원문: " $\alpha = 0.5$ (equal weights to both carbon and latency costs)" / "results would change with other α values"

<https://arxiv.org/pdf/2106.11750>


— 원문: "The optimization outcome changes depending on the desired tradeoffs between carbon footprint and efficiency"

셋째, 실제 시스템 구현과 시공간 통합이 아직 만나지 않았다. CICS 는 프로덕션 배포 사례이나 시간 축에 한정되고, CASPER 와 VMware GSLB 는 공간 축에 한정된다. CarbonFlex 는 용량 제약을 다루지만 단일 클러스터 안에 머문다. 두 축을 함께 다룬 Sukprasert 등의 연구는 시스템 구현이 아니라 상한 분석이다. 즉 용량 제약이 존재하는 조건에서 두 축을 결합한 시스템의 실제 절감량은 아직 보고된 바 없다.

5. 제안하는 방법

5.1 개요

CAST 는 예측, 공간 이동, 시간 이동의 세 단계로 구성된다. 예측 단계는 리전별로 향후 24 시간의 탄소집약도를 산출한다. 공간 이동 단계는 매 1 시간 슬롯마다 그 슬롯에 제출된 작업의 실행 리전을 결정한다. 시간 이동 단계는 배정된 리전 안에서 각 작업의 실행 시각을 마감 이내로 결정한다. 세 단계는 세 가지 데이터만 주고받는다. 예측 단계는 리전별 24 개 값의 배열을 넘기고, 공간 이동 단계는 작업별 실행 리전을 넘기며, 시간 이동 단계는 작업별 실행 시각과 배출량을 산출한다. 각 단계는 다른 단계의 내부 구현을 알지 못한다.



기존 연구는 현재값 1개로 리전만 정한다. CAST는 24 h 곡선으로 리전과 실행 시각을 함께 정한다.

그림 1. CAST의 전체 파이프라인 — 리전별 LSTM이 예측한 탄소집약도 곡선을 공간 이동과 시간 이동이 함께 쓰며, 시간 이동은 공간 이동이 계산한 슬롯별 잔여 용량을 참조해 실행 시각을 정한다.

그림 1은 세 단계의 연결과 각 단계가 주고받는 데이터를 나타낸다.

설계 원칙은 세 가지다.

첫째, 공간 이동을 먼저 적용하고 시간 이동을 보완적으로 적용한다. 시간 이동을 단독 수단으로 두지 않는 이유는 다수 리전에서 일간 변동성이 작기 때문이다. 선행 연구는 전 세계 70% 이상의 리전이 일간 변동성이 낮으며, 24 시간 여유를 가정한 시간 이동 단독의 전 지구 평균 절감이 8.4%에 그친다고 보고하였다. <https://doi.org/10.1145/3627703.3650079> — 원문: "more than 70% of regions worldwide have low daily carbon-intensity variations due to their reliance on fossil fuel-based, hydro, or nuclear power generation." — 원문: "the carbon reductions vary from 31 g·CO₂eq to 127 g·CO₂eq, 8.4% and 34% relative to the average global emissions"

둘째, 탄소와 지연 사이의 가중치를 고정 상수로 두지 않는다. 리전 간 탄소집약도 격차는 시각에

따라 변하므로, 옮겨서 얻는 이득이 큰 시간과 그렇지 않은 시간에 동일한 가중치를 적용하는 것은 최적이라 보기 어렵다.

셋째, 배치 결정은 예측값으로 수행하고 배출량 산정은 실측값으로 수행한다. 예측값으로 결정하고 예측값으로 채점하면 예측 오차의 대가가 결과에서 사라진다.

5.2 표기와 형식화

작업 집합을 J , 리전 집합을 R , 슬롯 집합을 T 로 둔다. 슬롯 길이는 1 시간이며, 탄소집약도 데이터의 시간 해상도와 일치시킨 값이다(Electricity Maps는 시간 단위로 탄소집약도를 제공한다, <https://www.electricitymaps.com/data/methodology>). 작업 j 는 출발 리전 o_j , 제출 시각 s_j , 실행 시간 d_j , 지연 등급 k_j , 지연 예산 L_j 를 갖는다. 작업의 마감은 $D_j = s_j + L_j + d_j$ 다.

목적함수는 총 배출량이다.

$$\min \sum_{j \in J} P \int_{\tau_j}^{\tau_j + d_j} C_{r(j)}(t) dt \quad \dots (1)$$

여기서 $r(j)$ 는 $x_{jr} = 1$ 인 리전이고 P 는 작업의 소비 전력이다. 제약은 네 가지다.

$$\sum_{r \in R} x_{jr} = 1, \forall j \in J \quad \dots (2)$$

$$|\{j: r(j) = r, \tau_j \leq t < \tau_j + d_j\}| \leq [\eta \cdot cap_r], \forall r \in R, \forall t \quad \dots (3)$$

$$s_j \leq \tau_j, \tau_j + d_j \leq D_j, \forall j \in J \quad \dots (4)$$

$$(\tau_j - s_j) + \ell_{ojr(j)} \leq L_j, \forall j \in J \quad \dots (5)$$

식 (2)는 모든 작업이 정확히 한 리전에 배정됨을, 식 (3)은 어느 시각에도 리전의 동시 실행 작업 수가 여유율을 적용한 용량을 넘지 않음을, 식 (4)는 실행이 제출 이후이고 마감 이내임을, 식 (5)는 시간 이동에 따른 지연과 네트워크 지연의 합이 지연 예산을 넘지 않음을 뜻한다. 다만 식 (5)는 본 구현에서 명시적으로 강제되지 않으며, 네트워크 지연 행렬의 최댓값 244 ms 가 가장 짧은 지연 예산보다도 작아 수치상으로도 구속되지 않는다.

여유율을 적용한 이 상한은 §5.6 에서 $K_r = [\eta \cdot cap_r]$ 로 다시 표기한다. 식 (3)의 우변과 식 (13)의 K_r 은 같은 값이다.

식 (3)이 본 연구의 형식화가 선행 연구와 갈라지는 지점이다. 두 축을 결합한 상한 분석을 수행한 선행 연구는 용량 제약을 공간 이동 단독 분석에서만 도입하고 두 축을 결합한 분석에서는 도입하지 않았다. <https://doi.org/10.1145/3627703.3650079> — 원문: "Since the scenario where all datacenter regions possess an unbounded capacity is not feasible, we also aim to assess the potential reductions under a constrained setting by considering capacity constraints."

식 (1)~(5)를 단일 정수 계획 문제로 푸는 것은 두 가지 이유로 채택하지 않았다. 첫째, 규모다. 작업 14만 6천 건에 리전 8개, 24시간 예측 지평을 곱하면 이진 변수가 $146,000 \times 8 \times 24 = 28,032,000$ 개를 넘는다. 둘째, 온라인성이다. 작업은 미리 주어지지 않고 시간에 따라 도착하며, 배정 시점에 이후 도착할 작업을 알 수 없다.

5.3 탄소집약도 예측

예측 모듈은 리전마다 독립된 LSTM 모델을 둔다. 입력은 과거 168 시간, 즉 1 주일의 시퀀스다.

168 시간을 택한 이유는 대상 신호가 24 시간 주기와 함께 주간 주기를 갖기 때문이다. 선행 연구는 하이퍼스케일 데이터센터가 위치한 40 개 리전 중 35 개가 24 시간 주기를 주기성 점수 0.5 이상으로 나타냈고 상당수가 주간 주기도 함께 보였다고 보고하였다. <https://doi.org/10.1145/3627703.3650079> — 원문: "35 of the 40 regions (87%) exhibit a 24-hour period... with a periodicity score of 0.5 or higher"

입력 피쳐는 10 종이다. 탄소집약도, 무탄소 전원 비중, 재생에너지 비중, 시간 주기성을 나타내는 $\sin \cdot \cos$ 쌍 3 종, 공휴일 플래그로 구성된다. 기상 데이터가 확보된 3 개 리전(캘리포니아, 텍사스, 독일)은 과거 기상 관측·예보 변수(풍속, 일사량 등)가 추가되어 12 종을 사용하며, 향후 24 시간 기상 예보를 LSTM 은닉 상태와 결합하는 별도 헤드를 둔다. 이 세 리전을 택한 것은 풍력·태양광 비중이 높아 변동성이 큰 계통이기 때문이다.

다만 이 세 리전의 기상 입력에는 한계가 있다. 평가에 쓴 향후 24 시간 기상 예보는 실제 예보 API가 아니라, 그 시각에 실제로 관측된 기상값을 그대로 가져다 쓴 것이다. 즉 예보 오차가 0 인 이상적인 상황을 가정한 셈이며, 실제 예보 API를 쓰면 이 세 리전의 예측 성능과 거기서 이어지는 절감 효과가 지금 보고한 값보다 낮아질 수 있다.

학습·검증·평가 구간은 시간순으로 분리한다. 2021 년부터 2023 년까지를 학습에, 2024 년을 검증에, 2025 년을 평가에 사용한다. 입력 구간 초반의 결측(2025 년 1 월 1 일부터 7 일까지)은 1 월 8 일의 프로파일을 반복해 채운다. 평가는 롤링 예측 방식으로 수행한다. 즉 평가 구간의 각 시각마다 그 시점까지의 관측만을 입력으로 향후 24 시간을 예측하고, 시각을 한 시간씩 전진시키며 이를 반복한다.

CAST 는 발전원별 생산량을 먼저 예측하고 배출계수를 적용하는 2 단 구조 대신 탄소집약도를

직접 예측한다. 발전원별 시간 단위 공개 예보가 확보된 리전이 캘리포니아에 한정되어, 한국·일본·인도를 포함하는 본 연구에서는 직접 예측이 데이터 가용성이 낮은 리전에 유리하기 때문이다. <https://doi.org/10.1145/3538637.3538849>

5.4 공간 이동 — 슬롯 단위 정수 계획 라우팅

공간 이동 단계는 매 슬롯마다 다음 다섯 가지를 수행한다. 첫째, 그 슬롯에 제출된 작업을 수집한다. 둘째, 예측 모듈로부터 리전별 탄소집약도 예측값을 받는다. 셋째, 탄소 비용과 지연 비용을 각각 정규화한다. 넷째, 정수 계획 문제를 풀어 배정을 확정한다. 다섯째, 배정된 작업을 실행 시간 동안 해당 리전의 용량에 반영한다.




그림 2. 공간 이동(로드밸런서) — 슬롯마다 파레토 무릎점으로 α 를 자동 결정해 리전 용량 제약 안에서 작업을 배정하는 슬롯 단위 ILP 다.

그림 2 는 예측·지연 행렬·직전 배정이라는 세 입력에서 출발해 배정 확정까지 이어지는 처리 순서를 보여준다.

두 비용은 서로 다른 방식으로 정규화한다. 탄소 비용은 슬롯마다 그 슬롯의 리전별 최댓값으로

나누고, 지연 비용은 전 구간에서 고정된 값인 지연 행렬의 최댓값 244ms 로 나눈다.

$$\tilde{c}_{Mr} = \frac{\hat{c}_r}{\max_{r'} \hat{c}_{r'}}, \tilde{\ell}_{or} = \frac{\ell_{or}}{244} \quad \dots (6)$$

탄소 비용만 슬롯별로 정규화하는 것은 슬롯 간 탄소 격차의 절대적 크기를 가중치 해석에서 분리하기 위함이다. 고정된 분모를 쓰면 전 리전이 함께 깨끗한 슬롯에서 탄소 향이 일률적으로 작아져, 같은 가중치가 슬롯마다 다른 의미를 갖게 된다.

슬롯의 배정 문제는 다음과 같다. 배치에 속한 작업을 j , 리전을 r , 배정 변수를 x_{jr} , 미배정 변수를 z_j 로 둔다.

$$\min \sum_j \sum_r \left(\alpha \tilde{c}_{Mr} + (1 - \alpha) \tilde{\ell}_{or} \right) x_{jr} + P_{\text{slack}} \sum_j z_j \quad \dots (7)$$


$$s.t. \sum_r x_{jr} + z_j = 1 \forall j, \sum_j x_{jr} \leq a_r \forall r \quad \dots (8)$$

a_r 은 여유율을 적용한 용량에서 현재 실행 중인 작업 수를 뺀 값이다. 미배정 변수 z_j 는 어떤 리전에도 배정할 수 없을 때 문제가 실행 불가능해지는 것을 막으며, P_{slack} 에 어떤 배정 비용보다 큰 값을 주어 배정이 가능한 한 선택되지 않도록 한다.

가중치 α 는 슬롯마다 파레토 무릎점으로 결정한다. 절차는 다음과 같다. 0 부터 1 까지 0.1 간격의 후보 11 개에 대해 각각 배정 문제를 풀어, 그 배정의 평균 네트워크 지연과 예상 배출량을 계산한다. 이렇게 얻은 11 개의 점을 두 축에 대해 각각 0 에서 1 로 정규화한다. 지연과 배출이 모두 0 인 이상점에 유클리드 거리가 가장 가까운 점을 택하고, 그 점에 해당하는 α 와 배정을 채택한다.

$$\alpha^* = \arg \min_{\alpha} \sqrt{\tilde{\lambda}(\alpha)^2 + \tilde{\mu}(\alpha)^2}, \tilde{\lambda}, \tilde{\mu} \text{ 는 } 0-1 \text{ 정규화한 평균 지연과 예상 배출} \quad \dots (9)$$

미배정이 발생하는 후보가 있으면 미배정 수가 최소인 후보들 안에서만 고르고, 거리가 같으면 작은 α 를 택한다.



◆ baseline($\alpha=0$) · ★ α =auto(슬롯별 무릎점, 평균 0.508).
 α =auto가 탄소 최저가 아니라 "한계수익이 정점을 찍는 지점"이다($\alpha=0.75$ 가 10,396.5kg으로 더 낮음)

그림 3. 고정 α 스윙과 슬롯별 무릎점(α =auto)의 파레토 곡선 — auto는 탄소가 가장 낮은 지점이 아니라 지연 대비 탄소 한계수익이 정점을 찍는 지점(464.9 kg/ms)이다.

그림 3 은 $\alpha=0$ (지연 최소)부터 $\alpha=1$ (탄소 최소)까지 고정값 스윙 결과와 auto의 위치를 같은 평면에 함께 표시해, auto가 두 극단과 어떻게 다른 지점을 택하는지 비교할 수 있게 한다.

고정 상수는 실패 방향이 슬롯에 따라 반대다. 리전 간 격차가 큰 슬롯에서는 옮길 수 있는 이득을 남긴 채 보수적으로, 격차가 작은 슬롯에서는 얻을 탄소가 적은데도 지연을 지불하며 공격적으로 동작한다. 무릎점 선택은 두 축을 정규화한 곡선의 기하만 사용하므로 평가자가 정한 별도의 가중치를 요구하지 않는다.

. <https://doi.org/10.1145/3634769.3634812> — 원문: "results would change with other α values. This is primarily due to the fact that CASPER would redirect requests differently due to the trade-off between carbon emissions and the number of servers needed to satisfy latency SLOs." <https://arxiv.org/pdf/2106.11750> — 원문: "The optimization outcome changes depending on the desired tradeoffs between carbon footprint and efficiency"

5.5 시간 이동 — 마감 내 슬롯 선택

시간 이동 단계는 작업 j 의 실행 가능 윈도우를 $[t_{\text{early}}, t_{\text{late}}] = [s_j, D_j - d_j]$ 로 둔다. 후보는 이 윈도우 안의 1시간 슬롯이다. 후보를 애초에 마감

이내에서만 탐색하므로, 이 단계에서 마감 위반은 정의상 발생하지 않는다. 윈도우가 비면 즉시 실행한다. 지연 예산이 슬롯 길이인 1시간보다 짧은 작업이 여기에 해당하며, 이들에게는 시간 이동이 적용되지 않는다.

후보 슬롯 t 의 점수는 정규화한 탄소 비용과 지연 비용의 가중합이다.

$$\hat{c}(t) = \frac{\tilde{c}(t) - c_{\min}}{c_{\max} - c_{\min}}, \hat{d}(t) = \frac{t - t_{\text{early}}}{t_{\text{late}} - t_{\text{early}}} \quad \dots (10)$$

$$\text{score}(t) = \alpha(k) \hat{c}(t) + (1 - \alpha(k)) \hat{d}(t), \alpha(k) = \frac{6-k}{5} \quad \dots (11)$$

$\tilde{C}(t)$ 는 t 부터 실행 시간 동안의 예측 탄소집약도 평균이고, $C_{\min}$ 과 $C_{\max}$ 는 후보 집합 안에서의 최솟값과 최댓값이다. 가중치는 작업이 신고한 지연 등급의 함수로 정의한다. 등급 k 가 작을수록, 곧 여유가 클수록 탄소 향의 비중이 커진다. 최소 등급 $k=1$ 에서 $\alpha=1.0$ 이 되어 지연 향이 사라지고 가장 깨끗한 슬롯이 선택되며, 최고 등급 $k=5$ 에서 $\alpha=0.2$ 가 되어 지연 향이 지배하고 사실상 즉시 실행된다.

이 단계의 가중치를 무릎점으로 결정하지 않는 이유는 결정 단위가 다르기 때문이다. 공간 이동은 슬롯 안의 작업 집합을 한꺼번에 배정하므로 후보 가중치마다 곡선이 정의되지만, 시간 이동은 작업 하나의 실행 시각을 정하므로 그러한 곡선이 없다. 대신 작업이 제출 시 신고한 지연 등급을 가중치로 직접 사용한다.

본 단계는 리전의 용량을 고려하지 않는다. 즉 후보 슬롯을 고를 때 그 슬롯에 이미 배정된 작업 수를 참조하지 않으며, 각 작업이 독립적으로 자신의 최적 슬롯을 선택한다. 이 설계 결정이 어떤 결과를 낳는지는 검증 절에서 측정한다. 용량을 인지하는 온라인 시간 이동은 다음 절(§5.6)에서 다룬다.

예측 지평을 벗어나는 경우는 즉시 실행으로 처리한다. 예측 모듈은 현재 시각으로부터 24 시간까지만 값을 제공하므로, 실행 가능 윈도우의 시작이 그 지평을 넘으면 비교할 근거가 없다.




그림 4. 시간 이동(스케줄러) — 마감 인지 탐색 윈도우 안에서 탄소·지연 가장 점수가 최소인 실행 슬롯을 고른다.

그림 4는 그림 2가 정한 리전 배정을 이어받아, 같은 파이프라인이 이번에는 실행 시각을 정하는 두 번째 단계임을 보여준다.

5.6 용량 인지 온라인 시간 이동

§5.2에서 식 (3)으로 리전별 동시 실행 상한을 선언했지만, 앞 절의 시간 이동 단계는 이 제약을 실제로 강제하지 않았다. 이 절은 그 제약을 알고리즘 수준에서 강제하는 방법을 제시한다.

먼저 리전 r , 시각 t 에서 남은 자리를 정의한다.

$$n_r(t) = \{j: r(j) = r, \tau_j \leq t < \tau_j + d_j\}, a_r(t) = K_r - n_r(t) \quad \dots (13)$$

식 (3)을 자리 형태로 다시 쓴 것이다. 작업 하나를 t' 에 놓을 수 있으려면 시작 시점만이 아니라 실행이

끝날 때까지 매 순간 자리가 있어야 한다: $\text{feasible}(j, t') \Leftrightarrow \min a_r(j)(u) \geq 1, u \in [t', t' + d_j]$.

다음으로, 슬롯 t 에서 지금이 남은 탐색 구간 안에서 최선인 작업들을 고른다.

$$Q(t) = \{j: s_j \leq t, \tau_j \text{ 미정}\}, P_r(t) = \left\{j \in Q(t): r(j) = r, \arg \min_{t' \in W_j(t)} \text{score}_j(t') = \max(t, s_j)\right\} \quad \dots (14)$$

score는 §5.5의 식 (11)을 그대로 쓰되, 예측은 그 슬롯에서 새로 발행된 최신값을 쓴다. 제출 시점에 한 번 받은 예측을 재검토 없이 끝까지 쓰는 사전 예약형과 달리, 롤링형은 매 슬롯 다시 확인한다 — 미래를 안다고 가정하지 않는다는 뜻이다.

자리가 $P_r(t)$ 의 크기보다 적으면 누구를 먼저 넣을지 정해야 한다. 남은 여유가 가장 적은 작업을 먼저 넣는다 — 순수 EDF(Earliest Deadline First)다.

$$u_j(t) = (D_j - d_j) - t, F_r(t) = \{j \in Q(t): r(j) = r, u_j(t) < 1\}, R_r(t) = P_r(t) \setminus F_r(t) \text{를 } u_j(t) \text{ 오름차순 정렬}, S_r(t) = F_r(t) \cup R_r(t)[1 \dots \max(a_r(t) - |F_r(t)|, 0)] \quad \dots (15)$$

$j \in S_r(t)$ 이면 $\tau_j \leftarrow \max(t, s_j)$ 로 확정한다.

세 가지를 밝혀둔다. 첫째, 우선순위는 탄소 이득이 아니라 순수하게 남은 여유다. 탄소 이득으로 정렬하면 나중에 측정할 지표로 지금 순서를 정하는 셈이라 순환 논리가 된다. 둘째, $F_r(t)$ 는 $P_r(t)$ 안이 아니라 $Q(t)$ 전체에서 고른다 — 그렇지 않으면 지금이 최선이 아닌 마감 임박 작업이 누락되어 무한정 밀릴 수 있다. 셋째, $|F_r(t)|$ 가 $a_r(t)$ 보다 많으면 그 슬롯은 의도적으로 상한을 넘긴다 — 마감을 지키기 위한 선택이며, 이 초과는 용량 위반으로 따로 집계한다(§6.4).

Algorithm 1은 이 규칙을 슬롯 단위로 반복한다.

Algorithm 1 슬롯 단위 롤링 재평가

Input: K_r , $\hat{C}_r(t)(\cdot)$, H , 작업 집합

Output: 모든 j 에 대한 τ_j

```

1:  $Q \leftarrow \emptyset$ 
2: for  $t \leftarrow 0$  to  $t_{\max}$  do
3:    $Q \leftarrow Q \cup \{j : [s_j] = t\}$ 
4:   for each  $r \in R$  do
5:      $a_r(t) \leftarrow K_r - n_r(t)$ 
6:      $F \leftarrow \{j \in Q : r(j)=r, u_j(t) < 1\}$ 
7:      $P \leftarrow \emptyset$ 
8:     for each  $j \in Q$  with  $r(j)=r, j \notin F$  do
9:        $W_j(t) \leftarrow$  실행 가능 윈도우
10:      if  $\operatorname{argmin}_{t' \in W_j(t)} \operatorname{score}_j(t') = \max(t, s_j)$  then
11:         $P \leftarrow P \cup \{j\}$ 
12:      sort  $P$  by  $u_j(t)$  ascending
13:       $S \leftarrow F \cup P[1 \dots \max(a_r(t) - |F|, 0)]$ 
14:      for each  $j \in S$  do
15:         $\tau_j \leftarrow \max(t, s_j); Q \leftarrow Q \setminus \{j\}$ 
16:      if  $Q = \emptyset$  and 남은 도작 없음 then break

```

이 알고리즘은 두 가지를 보장한다. 첫째, 어떤 작업도 무한히 연기되지 않는다. 슬롯이 하나 지날 때마다 $u_j(t)$ 는 정확히 1 씩 줄어든다. 시작 값이 유한하므로 유한한 슬롯 수 안에 $u_j(t) < 1$ 에 도달하고, 그 순간 $F_r(t)$ 에 들어가 용량과 무관하게 실행이 확정된다. 둘째, 마감 위반은 0이다. 후보 슬롯 $W_j(t)$ 의 모든 원소는 애초에 $D_j - d_j$ 이하로만 잡히고, $F_r(t)$ 편입 조건($u_j(t) < 1$) 자체가 아직 늦지 않은 마지막 순간에만 강제하므로, 마감을 넘긴 배정은 탐색 공간에 아예 존재하지 않는다.

슬롯당 계산 비용은 그 슬롯의 대기 작업 수와 예측 지평 H 의 곱에 비례한다.

실측으로는, 공간 이동의 무릎점 탐색(슬롯당 α 후보 11개에 대한 ILP)이 슬롯당 평균 174 ms, 최악 890 ms이며 1년 전체로는 약 25분이 걸린다. 시간 이동의 롤링 재평가는 이보다 훨씬 가벼워 1년치 146,000건 전체가 약 7.6초에 끝난다(단일 실행, 데이터 로딩 제외).

5.7 탄소 회계

배치 결정은 예측값으로 수행하고, 배출량 산정은 실측값으로 수행한다. 작업 j 의 배출량은 실행 리전의 실측 탄소집약도를 실행 구간에 대해 적분한 값에 소비 전력을 곱한 값이다.

$$E_j = P \int_{\tau_j}^{\tau_j + d_j} C_{r(j)}(t) dt \quad \dots (12)$$

실측 계열은 1시간 해상도이므로 적분은 실행 구간이 걸치는 각 시간 구간의 겹침 길이에 그 시간의 값을 곱해 합산하는 방식으로 계산한다. 소비 전력은 작업당 1kW 상수로 가정한다 — 실측값이 아니라 상대 비교를 위한 단순화 가정이다. 이 가정은 작업 간 전력 프로파일의 차이를 배출량 비교에서 제거하며, 그 결과 배출량 차이는 전적으로 실행 리전과 실행 시각의 차이에서만 발생한다. 실측 전력 프로파일이 반영되면 절감량의 구성비는 달라질 수 있으나, 리전·시각 선택이 배출량을 좌우한다는 결론 자체는 유지된다.

선행 연구 가운데 두 축을 결합한 상한 분석은 미래 탄소집약도를 완전히 아는 조건을 가정한다.

<https://doi.org/10.1145/3627703.3650079> — 원문: "Here, we assume perfect knowledge of the future carbon-intensity and job length." 본 연구는 결정에 예측값을 사용하므로 예측 오차의 대가가 결과에 반영된다.

여기서 밝혀줄 점이 있다. 슬롯 길이는 1 시간이지만, 온라인 시간 이동은 슬롯 경계에 묶이지 않고 작업이 제출된 시각을 기준으로 굴러간다. 그래서 지연 예산이 1 시간보다 짧은 $k=3, 4, 5$ 도 시간 이동의 대상에서 빠지지 않는다 — 예를 들어 15 시 54 분에 제출된 예산 10 분짜리 작업이 16 시 정각으로 6 분 미뤄지는 것은 슬롯을 넘나들어도 예산 안이다. 실제로 $k=3, 4, 5$ 가운데 544 건이 이렇게 지연되었고, 마감을 넘긴 작업은 하나도 없었다.

네트워크 지연은 8×8 리전 간 왕복 지연 실측 행렬을 사용하며, 최댓값은 244ms, 비대각 최솟값은 12ms 다 — Azure 리전 간 왕복 지연 통계다(<https://learn.microsoft.com/en-us/azure/networking/azure-network-latency>). 리전 용량은 8 개 리전에 균일하게 부여한다. 기준 배정에서의 리전별 최대 동시 실행 수에 1.2 를 곱해 16 을 얻고, 여기에 여유율 0.8 을 적용하여 유효 상한 12 를 사용한다. 정수 계획 문제는 PuLP 인터페이스를 통해 CBC 솔버로 푼다.

6. 검증

6.1 실험 설정

평가는 8 개 리전의 2025 년 실측 탄소집약도 1 년치 위에서 수행한다. 탄소집약도는 Electricity Maps API 를 통해 1 시간 해상도로 수집하였다 — 발전과 설비를 모두 포함하는 전과정 배출계수 체계를 쓰는 공식

방법론이다(<https://www.electricitymaps.com/data/methodology>).

워크로드는 총 146,000 건이며 리전당 하루 50 건이 제출된다. 도착률과 지연 등급별 분포(3 : 2 : 1 : 1 : 3)는 실측 트레이스를 확보하지 못해 설정한 합성 파라미터다. 각 작업은 지연 등급 $k \in \{1, \dots, 5\}$ 를 신고한다. 등급은 지연 예산으로 사상된다. $k=1$ 은 12~24 시간, $k=2$ 는 2~8 시간, $k=3$ 은 2~10 분, $k=4$ 는 15~60 초, $k=5$ 는 1~5 초다. 각 등급 안에서는 로그균등 분포로 표본을 추출한다.

6.2 예측 정확도

예측 모듈의 정확도를 리전별로 평가하고, 직전 실측값을 그대로 다음 시각의 예측으로 쓰는 지속성 기준선과 비교하였다. 지표는 정규화 평균절대오차이며 리전별 평균 탄소집약도로 나누어 리전 간 비교가 가능하도록 하였다.

표 1. 예측 지평별 정규화 평균절대오차 (8 개 리전 평균)

예측 지평	LSTM (%)	지속성 기준선 (%)	LSTM 우세 리전
1 시간	10.06	4.97	0 / 8
6 시간	13.22	22.28	8 / 8
24 시간	14.90	13.15	2 / 8

결과는 예측 지평에 따라 갈린다. 1 시간 지평에서는 지속성 기준선이 8 개 리전 전부에서 LSTM 보다 정확하다. 탄소집약도가 한 시간 사이에 크게 변하지 않으므로 직전 값을 그대로 쓰는 것이 강한 기준선이 된다. 6시간 지평에서는 관계가 뒤집혀 LSTM이 8 개 리전 전부에서 앞선다. 24 시간 지평에서는 독일과 텍사스 두 리전에서만 LSTM 이 앞선다.

이 결과는 시스템의 두 단계에 서로 다르게 작용한다. 공간 이동 단계는 현재 슬롯의 리전별 값만 필요하므로 1 시간 지평을 사용하며, 이 구간에서 LSTM은 지속성 기준선보다 나은 정보를 주지 못한다. 반면 시간 이동 단계는 향후 24 시간 곡선 전체에서 가장 낮은 시각을 찾아야 하므로 6 시간 이후 구간의 정확도가 중요하다.

프랑스에서 격차가 가장 크다. 1 시간 지평에서 LSTM 이 27.14%, 지속성 기준선이 10.29%다. 다만 프랑스의 연평균 탄소집약도는 13.5 gCO₂/kWh 로 8 개 리전 중 가장 낮아, 같은 절대오차라도 백분율로는 크게 나타난다. 이 값은 상대 비교에만 사용해야 한다.

예측 품질이 최종 배출량에 미치는 영향도 측정하였다. 스케줄러에 넣는 탄소집약도 계열만 바꾸고 나머지 로직을 동일하게 두었을 때, 예측값을 쓰면 9,958.2 kg, 24 시간 전 실측값을 쓰면 9,977.6 kg, 미래를 완전히 아는 경우 9,647.1 kg 이다. 예측 모듈이 24 시간 전 실측값 대비 얻는 것은 19.4 kg 으로 전체 절감량의 0.07%에 그친다. 즉 본 시스템의 절감은 예측 정확도가 아니라 배치 결정 구조에서 나온다.

6.3 주요 결과

세 단계를 동일한 회계로 비교하였다. 첫째 단계는 홈 리전에서 즉시 실행하는 기준이고, 둘째 단계는 탄소 인지 공간 이동을 적용한 뒤 즉시 실행하며, 셋째 단계는 여기에 시간 이동을 더한 것이다. 모든

단계에서 배치 결정은 예측값으로, 배출량 산정은 실측값으로 수행하였다.

표 2. 단계별 총 배출량과 절감률

단계	총 배출량 (kg)	기준 대비 (%)	추가 절감 (%p)
① 홈 리전 즉시 실행	29,225.6	—	—
② 탄소 인지 공간 이동	12,609.8	-56.85	-56.85
③ ② + 시간 이동 (용량 미강제)	9,958.2	-65.93	-9.07
③' ② + 시간 이동 (사후 용량 강제)	11,873.0	-59.37	-2.52
④ ② + 시간 이동 (용량 인지, 온라인)	10,805.0	-63.03	-6.18




그림 7. 다섯 방식의 총 배출량 비교(표 2) — (a)전체, (b)①을 제외하고 x 축을 확대한 것이며 점선은 ④ 값이다. 온라인 용량 인지(④, 10,805.0 kg, -63.03%)는 아무것도 안 했을 때(①)와, 용량 제약을 전혀 고려하지 않아 실현 불가능한 반사실 상한(③, 9,958.2 kg) 사이에 위치한다.

그림 7은 표 2의 다섯 방식을 (a)전체와 (b)확대 두 패널로 나누어, ④가 두 경계(①의 손해, ③의

이상치) 사이 어디에 실제로 도달하는지를 세밀하게 비교할 수 있게 한다.

공간 이동만으로 총 배출량이 56.85% 감소한다. 시간 이동 단계가 리전 용량을 고려하지 않으면 65.93%까지 내려가지만, 이는 실현 불가능한 반사실 상한이다. 배치가 끝난 뒤 사후적으로 용량을 강제하면 59.37%에 그치는데, 이는 아무 것도 하지 않았을 때 감수해야 할 손해의 하한이다. 이 두 경계값 사이 어디에 실제 값이 있는지는 6.4 절에서 온라인 용량 인지 알고리즘으로 확정한다.

작업 146,000 건은 전량 마감 이내에 처리되어 마감 위반은 발생하지 않았다. 시간 이동 단계가 후보 슬롯을 마감 이내에서만 탐색하므로 이는 설계상의 결과다. 공간 이동에 따른 평균 네트워크 지연은 36.2 ms, 95 백분위수는 137 ms 이며 홈 리전 처리 비율은 56.3%다.

시간 이동의 절감은 지연 등급에 따라 극단적으로 치우친다.

표 3. 지연 등급별 시간 이동 절감 기여

등급	작업 수	지연 예산	절감량 (kg)	비중 (%)
k=1	43,830	12~24 시간	1,692.8	93.79
k=2	14,458	2~8 시간	111.9	6.20
k=3	14,716	2~10 분	0.0	0.00
k=4	29,244	15~60 초	0.0	0.00
k=5	43,752	1~5 초	0.0	0.00

절감의 93.79%가 k=1 한 등급에서 나오고 6.20%가 k=2 에서 나온다. k=3 이하는 지연 예산이 슬롯 길이인 1 시간보다 짧아 옳길 슬롯이 거의 없어, 셋을 합쳐도 절감은 0.1kg 에 그친다. 이들이 전체 작업의 60.1%인 87,712 건이다. 즉 본 시스템의 시간 이동은 절감의 대부분을 여유가 가장 큰 두 등급(k=1, k=2)에서 만든다. 슬롯 길이를 줄이면 k=3 이하의

기여도 늘어날 수 있으나 정수 계획 문제를 푸는 횟수가 그만큼 늘어난다.

6.4 용량 제약과 시간 이동

시간 이동 단계는 리전 용량을 고려하지 않는다. 이 설계 결정이 낳는 결과를 측정하였다. 리전 r 의 시각 t 에서 동시 실행 중인 작업 수는 모든 작업의 시작 시각과 종료 시각에서의 누적합으로 산출하였다. 이는 로드밸런서가 용량을 산정할 때 쓰는 정의와 같다.

공간 이동만 적용한 단계에서는 8 개 리전 전부가 유효 상한인 12 건 이하를 유지한다. 이는 구조적 결과다. 로드밸런서는 슬롯 시작 시점에 아직 종료하지 않은 작업 수와 신규 배정 수의 합을 상한 이하로 제약하며, 실행 중 작업의 반환이 실제 종료보다 이르지 않으므로 슬롯 내 어느 시각에도 상한을 넘을 수 없다. 시간 이동을 적용하면 프랑스와 캘리포니아에서 41 건에 이르러 상한의 3.4 배가 되고, 연중 각각 622 시간과 867 시간 동안 상한을 초과한다. 나머지 6 개 리전은 초과가 전혀 없다(최댓값 0.00 시간).

두 리전의 성격은 상반된다. 캘리포니아는 초과 슬롯의 91.38%가 19 시부터 21 시까지 세 시간에 집중되고(균등 분포라면 12.5%), 좁게는 19 시와 20 시 두 시간만으로도 82.15%를 차지한다. 프랑스는 상위 세 시간대가 30.2%로 분산되어 있다. 탄소집약도 사분위 범위도 캘리포니아가 86 에서 208, 프랑스가 5 에서 18 로 크게 다르다. 캘리포니아의 초과는 태양광이 만드는 좁은 저탄소 시간대로의 집중이고, 프랑스의 초과는 리전 전체가 항상 낮아 물량이 물리는 것이다.

이 초과가 실제로 얼마나 손해로 이어지는지 가늠하기 위해, 배치 시점에 용량을 전혀 모르는 극단적인 대조군을 일부러 만들었다. 배치가 끝난 뒤 사후적으로 상한을 초과한 작업을 시간 이동 이전의 시각으로 되돌리고, 초과가 사라질 때까지 반복하는

규칙이다. 프랑스는 5 회, 캘리포니아는 3 회 반복한 뒤 전 리전이 상한 이하로 수렴한다. 이 규칙은 배치 시점에 용량을 아는 스케줄러보다 항상 같거나 나쁜 결과를 내므로, 그 결과는 순진한 하한 — 아무 것도 하지 않았을 때 감수해야 할 손해의 크기다.

되돌린 작업은 31,250 건이다. 시간 이동의 대상을 $k=1:k=2$ 의 58,288 건으로 한정하는 샘플은 슬롯 정렬 모델에서나 성립한다 — 롤링 모델에서는 146,000 건 전체가 대상이 될 수 있으므로, 전체를 분모로 하면 21.4%가 되돌려진 샘플이다. 시간 이동이 만든 절감은 2,651.6 kg 에서 736.8 kg 으로 줄어 총 절감률은 65.93%에서 59.37%가 된다.

표 4. 사후 용량 강제의 리전별 분해

리전	최대 동시	초과 시간	되돌린 작업	손실 편익	건당 손실
캘리포니아	41	866.9	16,449	1,805.1	109.74
프랑스	41	622.4	13,258	54.3	4.10
나머지 6 개 리전	15~20	31 이하	1,543	55.4	—

주: 최대 동시는 건, 초과 시간은 시간, 손실 편익은 kg, 건당 손실은 g.


손실은 리전에 고르게 분포하지 않는다. 94.3%가 캘리포니아에서 발생하며, 되돌린 작업 한 건당 평균 손실이 캘리포니아 109.74 g, 프랑스 4.10 g 으로 26.8 배 차이난다. 프랑스는 되돌린 작업이 적지 않으나 손실은 54.3 kg 에 그친다. 탄소집약도가 종일 평탄한 리전에서는 실행 시각을 옮겨도 얻을 것이 없기 때문이다. 실제로 시간 이동이 만든 절감 2,651.6 kg 가운데 캘리포니아 한 리전이 1,905.4 kg, 곧 71.9%를 차지하고 프랑스는 2.3%에 그친다.

선행 연구는 시간 이동의 절감이 어떤 조건에 의존하는지도 밝혔다.

<https://doi.org/10.1145/3627703.3650079> — 원문: "For real cloud workloads, the carbon reductions from temporal shifting are limited to 112 g-CO₂eq, and depend heavily upon factors like long job lengths, substantial slack, absence of resource constraints, and

[access to future knowledge of carbon-intensity.](#)" 본 절이 측정된 것은 이 가운데 자원 제약의 부재라는 조건이 성립하지 않을 때의 결과다.

이 하한이 보여주는 손해를 줄이기 위해 용량 인지 온라인 시간 이동을 구현했다. 슬롯별로 리전 점유량을 추적하여 상한에 도달한 슬롯을 후보에서 미리 제외하는 방식이다. 그 결과 총 배출량은 10,805.0 kg, 기준 대비 63.03% 감소로, 순진한 하한(59.37%)보다 3.66%p 더 절감하면서 상한 위반을 대부분 제거한다 — 최대 동시 실행이 41 건에서 17 건으로, 캘리포니아의 초과 시간이 866.9 시간에서 7.25 시간으로, 프랑스는 622.4 시간에서 0.91 시간으로 줄어든다(표 2 ④행). 남은 상한 위반 배정 227 건은 전량 마감이 임박해 미룰 수 없는 작업(강제 편입 106 건, 즉시 실행 경로 121 건)에서 비롯되며, 알고리즘의 결함이 아니다. 즉 본 절의 두 실험은 한 쌍이다 — 앞서 켜 것은 아무 것도 하지 않았을 때의 하한이고, 이 결과는 그 손해의 대부분을 실제로 되찾을 수 있음을 보인 것이다.



위 구간은 연중 한 주(day 231~238)의 예시다.

연중 전체 최대 동시실행: 무제약 41건 → 온라인 17건(다른 주, §6.4 정의).

그림 5. 시간 이동 전후 캘리포니아 리전의 동시 실행 수 — 용량을 무시하면 상한(12 건)의 3.4 배인 41 건까지 몰리고, 온라인 용량 인지(Algorithm 1)로 17 건까지 억제된다.

그림 5 는 이 억제가 하루 중 특정 시간대에 몰리는지 살펴볼 수 있게 시계열로 나타낸 것으로, §6.4 에서 다루는 19~21 시 집중 현상의 근거가 되는 그래프다.

6.5 용량 스윙

리전 용량을 바꾸어 가며 같은 측정을 반복하였다. 여유율은 0.8 로 고정하였다. 각 용량에서 시간 이동을 다시 수행하고 결과를 기록하였다.

표 5. 용량 스윙 — 배출량, 시간 이동 기여, 강제·위반 배정, 평균 지연

용량(피크 대비)	총 배출량(kg)	절감률(%)	시간이동 기여(%p)	강제 편입	위반 배정	평균 지연(h)
6 (피크의 0.5 배)	12,260.3	58.05	+1.20	39,903	29,962	4.543
9 (피크의 0.75 배)	11,552.8	60.47	+3.62	25,357	3,565	4.051
12 (피크와 동일)	10,805.0	63.03	+6.18	13,223	227	2.968
18 (피크의 1.5 배)	10,127.1	65.35	+8.50	9,418	17	2.084
24 (피크의 2 배)	10,018.0	65.72	+8.87	8,807	4	1.872
무제약	9,996.2	65.80	+8.95	8,572	0	1.769

주: 절감률은 기준(홈 리전 즉시 실행, 29,225.6 kg) 대비. 시간이동 기여는 공간 이동만 적용했을 때(56.85%) 대비 증분. 강제 편입은 마감 임박으로 용량과 무관하게 확정된 배정, 위반 배정은 그중 상한을 초과한 슬롯에서 확정된 배정이다.

용량을 조일수록 시간 이동의 기여는 줄어든다 — 무제약에서 +8.95%포인트였던 기여가 가장 뾰족한 용량(피크의 0.5 배)에서는 +1.20%포인트로 준다.

그림 6 이 이 곡선을 보여준다. 용량이 줄수록 강제 편입과 위반 배정도 함께 늘어, 배치가 끝난 뒤 남는 여지 자체가 그만큼 줄어들기 때문이다.

용량 스윙은 부하가 어느 리전에 몰리는지도 보여준다.




그림 6. 리전 용량을 기준($\eta \cdot \text{cap}_r=12$)의 0.5 배~무제약으로 바꿔가며 본 총배출과 강제 편입 건수 — 용량이 늘수록 둘 다 줄지만 수익은 체감하며, 전 구간에서 마감 위반은 0 건이다.

그림 6 은 총배출(왼쪽 축)과 강제 편입 건수(오른쪽 축)를 같은 가로축 위에 나란히 놓아, 용량을 늘렸을 때 두 지표가 같은 방향으로 휘어지는지 한눈에 비교할 수 있게 한다.

표 6. 리전 그룹별 배출량 — 용량 최소(0.5×)와 무제약 비교

리전 그룹	배출량 용량 0.5×(kg)	배출량 무제약(kg)	변화율
프랑스	571.2	487.0	-14.7%
캘리포니아	4,448.7	2,450.3	-44.9%
나머지 6 개 리전	7,240.4	7,058.9	-2.5%

용량이 느슨해질수록 캘리포니아의 배출량이 가장 크게 줄어든다(-44.9%) — 태양광이 만드는 좁은 저탄소 시간대를 더 넉넉히 활용할 수 있기

때문이다. 나머지 6 개 리전은 거의 변하지 않는다(-2.5%). 캘리포니아가 시간 이동의 주된 수혜 리전이라는 관찰(\$6.4)은 용량 전 구간에서 일관된다.

본 절의 스윙은 스케줄러 단계(시간 이동)의 용량만 바꾼 것이다. 리전 자체는 로드밸런서 단계에서 이미 정해지므로, 로드밸런서가 참조하는 리전 용량을 함께 바꾸어 가며 저탄소 리전 간 부하를 재분배하는 스윙은 다루지 않았다 — 이는 향후 과제로 남긴다.

6.6 논의

세 가지 독립적인 실험이 같은 방향을 가리킨다 — 예측이 정확할수록 쓸림이 커진다. 용량을 인지하지 않는 롤링 재평가는 배출을 거의 줄이지 못하면서(9,958.2 kg → 9,996.2 kg, 차이 38.0 kg) 최대 동시 실행은 41 건에서 51 건으로, 상한 위반 배정은 20,208 건에서 25,992 건으로 오히려 늘어난다. 미래를 완전히 아는 오라클 예측을 주입하면 위반이 227 건에서 873 건으로 늘어난다 — 용량을 인지하는 조건에서도 같은 방향이다. 예측이 정확할수록 "지금 이 슬롯이 최선"이라는 판단이 여러 작업에서 같은 저탄소 구간으로 더 일관되게 수렴하고, 그 수렴이 곧 용량 초과를 만든다. 따라서 용량 인지는 부가 기능이 아니라 정확한 예측과 반드시 함께 있어야 하는 구성 요소다 — 예측만 개선하고 용량을 무시하면, 개선한 만큼 오히려 위험해진다.

두 비용을 직접 비교할 수 있다. 예측 오차의 비용은 실제 LSTM 예측(63.03%)과 완전예지 오라클(63.64%)의 차이인 0.61%포인트다. 용량 제약의 비용은 온라인 용량 인지(63.03%)와 용량을 무시한 반사실 상한(65.93%)의 차이인 2.90%포인트로, 예측 오차 비용의 4 배가 넘는다. 즉 예측을 더 잘하는 것보다 용량을 다루는 것이 더 큰 문제다.

세 가지 민감도 분석도 이 결론을 뒷받침한다. 작업량을 0.5 배에서 2 배까지 바꾸어도 마감 위반은 전 구간에서 0 으로 유지된다 — 정리 2 가 부하와 무관하게 성립함을 실측으로 확인한 것이다. 다만 2 배 부하에서 용량 위반 배정은 227 건에서 59,924 건으로 264.0 배 폭증한다. 용량 상한을 수요에 비례해 늘리지 않으면 이 알고리즘도 한계에 부딪힌다는 뜻이다. 예측 오차 민감도는 완만한 선형이다 — 노이즈 표준편차 10%포인트당 절감률이 약 0.6%포인트씩 줄어들며 절벽은 없다. 실제 LSTM 의 절감률(63.03%)은 오라클(표준편차 0%, 63.64%)과 표준편차 20%(62.54%) 사이에 위치해, 이 모델의 실효 예측 오차가 대략 10~20% 수준임을 시사한다.

7. 결론

본 논문은 탄소 인지 스케줄링 시스템 CAST 를 제안한다. 탄소와 지연 사이의 가중치를 슬롯마다 파레토 무릎점에서 자동으로 결정하고, 8 개 리전의 1 년치 실측 탄소집약도 위에서 공간 이동과 시간 이동의 결합 효과를 측정하였다. 예측 단계는 리전별 LSTM 으로 향후 24 시간의 탄소집약도를 산출하고, 공간 이동 단계는 슬롯마다 정수 계획으로 실행 리전을 결정하며, 시간 이동 단계는 마감 이내에서 실행 시각을 결정한다.

공간 이동만으로 총 배출량이 56.85% 감소하고, 시간 이동만으로는 18.60% 감소한다. 리전 용량 제약을 지키면서 둘을 결합하는 온라인 용량 인지 알고리즘(Algorithm 1)은 63.03%를 달성하며, 작업 146,000 건 전량이 마감 이내에 처리되어 마감 위반은 발생하지 않는다.

이 63.03%는 두 경계값 사이에 있다. 배치 시점에 용량을 전혀 고려하지 않으면 65.93%까지 오르지만, 이는 상한의 3.4 배(41 건)까지 동시 실행이 몰리는, 실현 불가능한 반사실 상한이다. 반대로 배치가 끝난 뒤 사후적으로 상한 초과분을 되돌리는 순진한

방식은 59.37%에 그친다 — 아무 것도 하지 않았을 때 감수해야 할 손해의 크기다. 온라인 용량 인지는 이 하한보다 3.66%포인트 더 절감하면서 상한 위반을 최대 동시 41 건에서 17 건으로 줄인다.

본 연구의 주된 발견은 총계가 아니라 그 분포에 있다. 시간 이동이 만든 절감의 71.9%가 캘리포니아 한 리전에서 발생하며, 용량 초과가 가장 심한 리전도 캘리포니아다. 캘리포니아에서 상한을 초과한 슬롯의 91.38%는 19 시부터 21 시까지 세 시간에 몰린다. 반면 탄소집약도가 종일 평탄한 프랑스는 배정 물량이 가장 많음에도 시간 이동 절감 기여가 2.3%에 그치고, 되돌려도 잃는 것이 거의 없다. 즉 시간 이동이 값어치를 만드는 리전과 용량 제약이 그 값어치를 가로막는 리전이 일치한다. 선행 연구가 시간 이동이 실질적으로 기여하는 예외로 이름을 붙인 리전이 바로 캘리포니아였다는 점에서, 본 연구는 그 예외가 발생하는 메커니즘과 그것이 용량에 의해 어떻게 제약되는지를 실측한 것이 된다.

<https://doi.org/10.1145/3627703.3650079> — 원문: "there are some exceptions where regions have low spatial gains and high temporal gains and yet result in relatively high net carbon reductions, such as California (US-CA) and Virginia (US-VA)"

한계는 네 가지다. 첫째, 시뮬레이션 평가다 — 실측 데이터 위에서 트레이스 재생 방식으로 검증했으며, 실제 클러스터 배포는 하지 않았다. 배치 시점에 용량을 아는 경우와 모르는 경우, 사후에 강제하는 경우를 같은 작업 집합에 나란히 적용해 비교해야 하므로, 이는 한 시스템의 실패포로는 애초에 동시에 짚 수 없는 비교다. 둘째, 캘리포니아·텍사스·독일 세 리전의 기상 예보 입력은 실제 예보 API가 아니라 해당 시각에 실측된 기상값을 그대로 가져다 쓴 것이다(§5.3) — 예보 오차가 0 인 이상적 상황을 가정한 셈이라, 이 세 리전의 예측 성능과 절감 효과는 실제보다 낙관적일 수 있다. 셋째, 예측 지평은 24 시간까지만 시험했다 — 원자료가 24 시간 예보까지만 있어 48 시간 지평은 시험할 수 없었다. 넷째, 솔버의 동물 처리 비결정성(재실행 시 총배출이 최대 0.14% 차이), 합성 워크로드

파라미터(도착률, 지연 등급 분포)의 근거 미비, 그리고 지연 행렬에서 미국 동부 리전을 버지니아로 근사한 점(뉴욕에는 해당 지역 Azure 리전이 없음, 실제 뉴욕 값은 이보다 5~8ms 가량 높을 것으로 추정됨)이 남은 한계다.

향후 과제는 넷이다. 첫째, 실제 기상 예보 API 연동으로 세 리전의 예보 누출을 제거하는 것이다. 둘째, 24 시간을 넘는 예측 지평을 시험할 수 있도록 원자료를 확장하는 것이다. 셋째, 수요 증가에 맞춘 용량 산정이다 — 작업량이 2 배로 늘면 본 알고리즘에서도 용량 위반 배정이 264.0 배로 폭증하므로, 고정 상한이 아니라 수요에 비례해 조정되는 용량 모델이 필요하다. 넷째, 실제 클러스터 배포를 통한 검증이다.