1. 서론

전 세계 데이터센터의 전력 소비는 2024년 약 415 TWh에서 2030년 945 TWh로 늘 것으로 전망되고[1], 유럽연합은 일정 규모 이상의 데이터센터에 에너지 사용 보고를 의무화했다[2]. 이미 가동 중인 설비에 바로 쓸 수 있는 방법의 하나가 탄소 인지 스케줄링, 곧 작업을 탄소가 적게 나오는 시각과 리전(클라우드 사업자가 데이터센터를 묶어 운영하는 지역 단위)으로 옮기는 것이다. 전력 1 kWh를 만들 때 나오는 탄소량인 탄소집약도는 발전원 구성에 따라 시각과 지역마다 다르다. 본 연구의 여덟 리전에서 2025년 평균은 인도 543.2, 프랑스 13.6 gCO_2/kWh로 약 40배 벌어진다. 마감 안에만 끝나면 되는 배치 작업은 이런 깨끗한 시각과 리전으로 옮길 여유가 있다.

선행 연구는 이 차이를 시간 축(CICS[3])이나 공간 축(CASPER[4], VMware의 전역 부하 분산[5])에서 써 왔다. 두 축을 함께 다룬 연구에는 리전 용량이 문제가 된다. 깨끗한 리전의 깨끗한 시각은 모든 작업에게 같으므로, 작업이 그곳으로 몰려 리전이 동시에 실행할 수 있는 작업 수를 넘기기 쉽다. 두 축을 결합해 절감의 최대치를 구한 Sukprasert 등[6]은 리전 용량을 두지 않았다. 이 정책을 본 연구의 합성 워크로드에 그대로 적용하면 작업 건수의 99.75%가 프랑스 한 리전으로 몰리고, 그 배정을 위반 없이 실행하려면 한 리전이 동시에 129개, 곧 모든 작업을 제출 리전에서 바로 실행할 때의 최대치(기준 피크 13)의 9.9배를 실행해야 한다. 용량을 다룬 Caspian[8]은 마감을 목적함수의 페널티로 완화하고, 용량과 마감을 함께 지키는 Zanotto 등[9]은 작업이 도착할 때 배정을 확정하고 다시 풀지 않는다.

본 논문은 마감을 지키면서 리전 용량 안에서 배출을 줄이는 스케줄러 CAST(Carbon-Aware Spatio-Temporal scheduler)를 제안한다. CAST는 한 시간을 한 슬롯으로 보고, 매 슬롯 대기 중인 모든 작업의 리전과 시작 시각을 하나의 선형 계획 문제로 다시 풀어 이번 슬롯에 시작하는 작업만 확정한다. 마감은 하드 제약으로 지키고, 용량은 상한을 넘긴 양에 가장 큰 페널티를 주는 소프트 제약으로 둔다. 탄소집약도는 리전마다 LSTM으로 24시간 앞까지 예측하고, 탄소와 왕복 지연 시간 사이의 가중치는 슬롯마다 파레토 무릎점 규칙으로 고른다.

8개 리전의 2025년 1년치 탄소집약도 위에서 CAST는 합성 워크로드의 배출을 71.93%, Azure VM 기록으로 만든 워크로드의 배출을 51.35% 줄였고, 두 워크로드 모두 상한 위반과 마감 위반이 없었다. 탄소만 고려하면 CAST는 상한 안에서 95.65%를 줄여 1년치를 미리 아는 Sukprasert 등의 정책과 0.98%p 차이이며, Caspian은 CAST보다 덜 줄이면서 5,582건이 마감을 넘겼다.

2장은 관련 연구, 3장은 CAST의 구성, 4장은 실험 결과, 5장은 결론과 향후 연구를 다룬다.