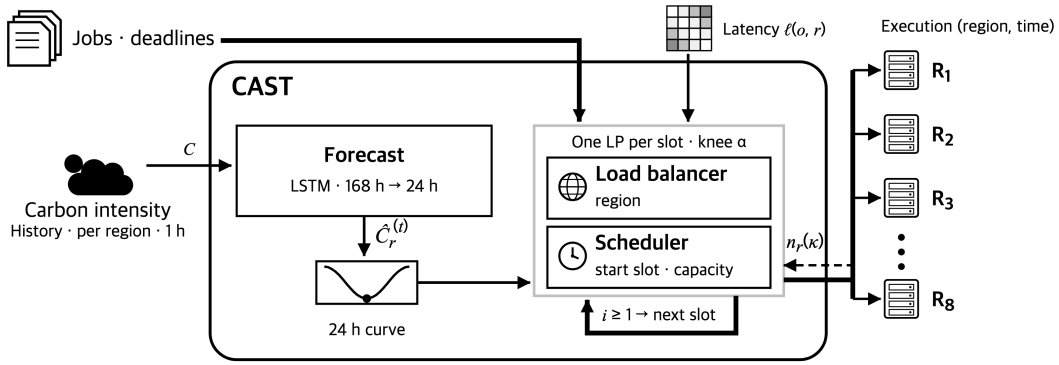



그림 1 CAST의 구성

Fig. 1 Overview of CAST

## 3. CAST 시스템

2장에서 본 선행 연구는 리전 용량과 작업 마감 가운데 하나를 양보하거나, 작업이 도착할 때 한 번 배정한 뒤 다시 배정하지 않거나, 탄소와 다른 목적 사이의 가중치를 사람이 정해 고정한다. CAST는 이 셋을 다음과 같이 다룬다. 마감은 반드시 지키고, 용량은 상한을 넘긴 양에 가장 큰 페널티를 부과한다. 1시간 단위의 슬롯마다 대기 중인 모든 작업의 리전과 시작 시각을 하나의 선형 계획 문제로 다시 풀고, 이번 슬롯에 시작하는 작업만 확정한다. 탄소와 지연 사이의 가중치는 정해진 규칙에 따라 슬롯마다 고른다. 매 기간 앞으로의 일정 구간을 다시 최적화하고 당장의 결정만 실행하는 이 구조는 생산계획과 모델 예측 제어(MPC)에서 쓰는 롤링 호라이즌(rolling horizon) 방식[13–15]이다.

### 3.1 문제 정의

그림 1은 CAST의 구성이다. 예측기는 리전마다 앞으로 24시간의 탄소집약도를 예측한다. 로드밸런서는 작업을 어느 리전에서 실행할지, 스케줄러는 언제 시작할지를 정하며, 통합 배정은 이 두 결정을 하나의 선형 계획 문제로 함께 정한다. 확정된 작업은 리전별 실행 현황에 반영되고, 다음 슬롯에서는 이 현황으로 리전별 남은 용량을 센다.

작업 $j$는 제출 리전 $o_j$, 제출 시각 $s_j$, 실행 시간 $d_j$, 허용 대기 시간 $L_j$를 가지며, 마감은 $D_j = s_j + L_j + d_j$다. 정할 값은 실행 리전 $r(j)$와 시작 시각 $\tau_j$다. 리전 $r$에서 시각 $t$에 실행 중인 작업 수를 $n_r(t)$, 리전 $r$의 동시 실행 상한을 $\mathrm{cap}_r$로 쓴다. 상한은 운영 주체가 그 리전에 확보한 전용 용량이다. 총 배출량은 다음과 같다.

$$E = \sum_{j \in J} P \int_{\tau_j}^{\tau_j + d_j} C_{r(j)}(t)\,dt \qquad (1)$$

$C_r(t)$는 리전 $r$의 실측 탄소집약도이고, $P$는 작업당 소비 전력이며 1 kW로 둔다. 배정은 예측값으로 정하고 배출량은 실측값으로 계산한다. 실측 자료가 1시간 단위이므로 적분은 실행이 걸친 슬롯들의 평균 탄소집약도에 실행 시간을 곱해 계산한다. 제약은 다음 둘이다.

$$s_j \le \tau_j, \quad \tau_j + d_j \le D_j \qquad \forall j \in J \qquad (2)$$

$$n_r(t) \le \mathrm{cap}_r + z_r(t),\ z_r(t) \ge 0 \quad \forall r \in R,\ \forall t \qquad (3)$$

식 (2)는 작업이 제출 뒤에 시작해 마감 안에 끝나야 한다는 뜻이다. 식 (3)의 $z_r(t)$는 상한을 넘긴 양이며, CAST는 이 양에 가장 큰 페널티를 부과한다. 마감은 어길 수 없는 제약으로 두고 용량은 페널티로 두므로, 마감이 임박한 작업이 상한보다 많은 순간에도 해가 존재한다.

### 3.2 예측기

예측기는 리전마다 따로 학습한 2층 LSTM이다(그림 2). 은닉 상태 차원은 64, 드롭아웃은 0.2다. 과거 168시간의 탄소집약도, 무탄소·재생 전력 비율, 시각·요일·월, 공휴일 여부를 입력받아 앞으로 24시간을 한 번에 예측한다. 캘리포니아, 텍사스, 독일은 풍속, 일사량, 기온을 함께 입력받는다. 2021~2023년 자료로 학습하고 2024년 자료로 검증했으며, 스케줄링 실험은 2025년 자료로 한다. 최적화기는 Adam(학습률 0.001), 배치 크기는 64다. 검증 오차가 더 줄지 않으면 조기 종료하며, 에폭(epoch)은 최소 20, 최대 150이다.

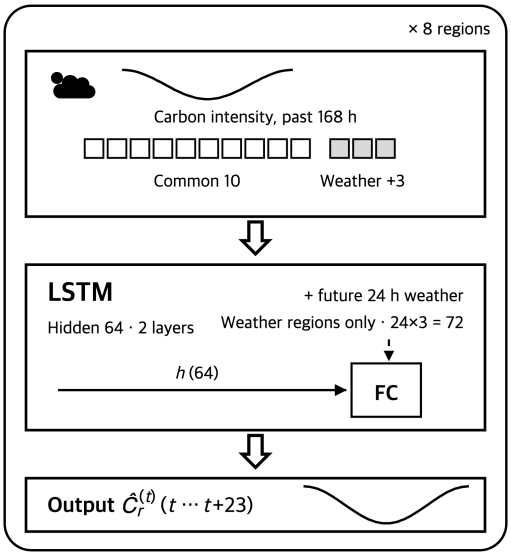



그림 2 리전별 LSTM 예측기의 구조
Fig. 2 Per-region LSTM forecaster

표 2 리전 간 왕복 지연 시간(ms)
Table 2 Inter-region round-trip latency (ms)

| Region | CA | TX | NY | FR | DE | KR | JP | IN |
|---|---|---|---|---|---|---|---|---|
| CA | 0 | 39 | 74 | 146 | 153 | 134 | 109 | 225 |
| TX | 39 | 0 | 38 | 113 | 125 | 153 | 128 | 244 |
| NY | 74 | 38 | 0 | 90 | 95 | 193 | 172 | 204 |
| FR | 146 | 113 | 90 | 0 | 12 | 238 | 228 | 137 |
| DE | 153 | 125 | 95 | 12 | 0 | 244 | 235 | 142 |
| KR | 134 | 153 | 193 | 238 | 244 | 0 | 30 | 122 |
| JP | 109 | 128 | 172 | 228 | 235 | 30 | 0 | 126 |
| IN | 225 | 244 | 204 | 137 | 142 | 122 | 126 | 0 |

### 3.3 로드밸런서

로드밸런서는 작업을 실행할 리전을 고른다. 후보는 여덟 리전이며, 리전 간 왕복 지연 시간(RTT)은 표 2와 같다. 값은 Azure의 리전 간 왕복 지연 통계[33]에서 가져왔고 1년 동안 고정한다. 뉴욕은 Azure 리전이 없어 가장 가까운 버지니아의 값을 쓴다.

작업을 제출 리전이 아닌 곳에서 실행하는 동안에는 자료가 리전 사이를 오가고, 그 경로의 장애에도 노출된다. 그래서 왕복 지연 시간 $\ell(o, r)$을 비용으로 두고 실행 시간에 비례하게 매긴다(3.5절). 지연 비용은 왕복 지연 시간을 표 2의 최댓값 244 ms로 나눈 값이다.

$$\tilde{\ell}(o,r) = \frac{\ell(o,r)}{244} \tag{4}$$

### 3.4 스케줄러

스케줄러는 작업의 시작 시각을 고른다. 슬롯 $t$가 시작하는 정각에 아직 시작하지 않은 작업을 모아 대기 작업 집합 $Q$를 만든다. 그 슬롯 안에 제출될 작업도 정각에 미리 알려진 것으로 가정해 함께 넣는다.

작업 $j$의 시작 후보는 현재 슬롯에서 $i$ 슬롯 뒤의 시각이다. $i$=0은 이번 슬롯에 시작하는 것으로, 정각과 제출 시각 가운데 늦은 때에 시작한다. $i\geq$1은 슬롯 $t$+$i$의 정각에 시작한다. $i$는 마감 안에 끝낼 수 있는 마지막 시작 시각과 예측 구간 $H$(24시간) 가운데 이른 쪽까지 둔다. 제출된 슬롯에서만 시작할 수 있는 작업을 연기 불가 작업이라 하며, 이 작업과 마지막 시작 시각까지 1시간이 남지 않은 작업은 $i$=0만 갖는다.

시작 후보의 탄소 비용은 그 시각부터 실행하는 동안의 예측 탄소집약도 평균을 슬롯 $t$ 예측 전체의 최댓값으로 나눈 값이다.

$$\tilde{C}_j(r,i) = \frac{\hat{C}_r^{(t)}(t+i, d_j)}{\max_{r',t'} \hat{C}_{r'}^{(t)}(t')} \tag{5}$$

$\hat{C}_r^{(t)}(t$+$i, d_j)$는 슬롯 $t$에 나온 예측으로 구한, 리전 $r$에서 $t$+$i$부터 $d_j$ 동안의 평균 탄소집약도다. 이번 슬롯의 첫 한 시간은 예측 대신 실측값을 쓴다.

스케줄러는 리전별 실행 현황으로 남은 용량을 센다. 이미 시작한 작업 수 $n_r$과 새로 배정될 작업 수의 합이 상한을 넘으면, 넘은 만큼이 초과량 $z^A$가 된다.

$$\begin{aligned} \textstyle\sum_{(j,i)\ni\kappa} x_{jri} + n_r(\kappa) &\leq \mathrm{cap}_r + z^A_{r\kappa} \\ \forall r,\ \kappa &\in U_t \cup [t+1, t+H] \end{aligned} \tag{6}$$

$(j, i) \ni \kappa$는 작업 $j$를 $i$ 슬롯 뒤에 시작했을 때 시각 $\kappa$에 실행 중임을 뜻한다. 이번 슬롯에서는 작업이 시작하는 순간마다 세며, 정각과 이번 슬롯 작업들의 제출 시각을 모은 집합이 $U_t$다. 미래 슬롯 $\sigma \in [t$+$1, t$+$H]$는 슬롯마다 한 번 센다. 연기 불가 작업은 도착한 슬롯에서 바로 실행해야 하므로, 연기 가능 작업($Q^{\mathrm{def}}$)의 미래 계획은 $\mathrm{cap}_r - \rho_r$ 이하로 제한해 예비 용량 $\rho_r$을 남겨 둔다. $z^B$는 이 한도를 넘긴 양이다.

$$\begin{aligned} \textstyle\sum_{(j,i)\ni\sigma,\ j\in Q^{\mathrm{def}}} x_{jri} + n_r(\sigma) \\ \leq \mathrm{cap}_r - \rho_r + z^B_{r\sigma} \\ \forall r,\ \sigma \in [t+1, t+H] \end{aligned} \tag{7}$$

대기 시간의 상한은 마감이 정하며, 비용이 같은 후보 사이에서는 일찍 시작하는 쪽을 고른다(3.5절).

### 3.5 통합 배정

통합 배정은 로드밸런서의 리전 후보와 스케줄러의 시작 후보를 묶어 (리전, 시작 시각) 쌍으로 고른다.

후보의 비용은 탄소 비용과 지연 비용을 가중치 $\alpha$로 더하고 실행 시간을 곱한 값이다.

$$c_j(r,i) = d_j\left[\alpha\tilde{C}_j(r,i) + (1-\alpha)\tilde{\ell}(o_j,r)\right] \quad (8)$$

$\alpha$=1이면 탄소만, $\alpha$=0이면 지연만 고려한다. 실행 시간을 곱하는 것은 긴 작업일수록 오래 배출하고 원격 리전을 오래 쓰기 때문이다. 슬롯 $t$의 배정 문제는 식 (6), (7)을 제약으로 하는 다음 문제다.

$$\min \textstyle\sum_{j\in Q}\sum_{r,i} c_j(r,i)x_{jri} + M_A\sum_{r,\kappa} z^A_{r\kappa} + M_B\sum_{r,\sigma\geq t+1} z^B_{r\sigma} + \varepsilon\sum_{j\in Q}\sum_{r,i} i\,x_{jri} \quad (9)$$

$$\textstyle\sum_{r,i} x_{jri} = 1, \qquad \forall j \in Q \quad (10)$$

$x_{jri}$는 작업 $j$를 리전 $r$에서 $i$ 슬롯 뒤에 시작하게 두는 변수이고, 식 (10)은 한 작업을 한 자리에만 배정한다는 뜻이다. 페널티는 $M_A \gg M_B \gg 1$로 두어 상한, 예비 용량, 탄소와 지연 순으로 우선한다. $M_B$는 가장 긴 실행 시간(시간 단위)의 2배로 두되 10보다 작지 않게 했고, $M_A$는 $M_B$의 100배다. 마지막 항은 비용이 같은 후보 사이에서 일찍 시작하는 쪽을 고르게 하며, $\varepsilon$은 $10^{-4}$다.

변수를 0~1 연속으로 두고 선형 계획법(LP)으로 푼다. 용량 제약과 배정 제약이 함께 있어 해가 늘 정수로 나오지는 않으므로, 정수가 아닌 해가 나온 슬롯만 정수 계획법(MILP)으로 다시 푼다. 그런 슬롯은 3.9%였다. 풀고 나면 $i$=0인 작업만 확정해 실행 현황에 반영하고, $i\geq$1로 정해진 작업은 다음 슬롯에서 새 예측으로 다시 배정한다.

실행 시간이 제출 시점에 알려져 있다고 가정하면 이 배정은 세 가지 성질을 갖는다. 마감을 넘기는 후보가 없으므로 마감 위반이 없다. 슬롯마다 마지막 시작 시각까지 남은 시간이 1시간씩 줄어 결국 $i$=0만 남으므로 무한히 연기되는 작업이 없다. 초과 변수가 있어 배정 문제는 늘 해를 가진다.

**알고리즘 1** CAST의 슬롯별 배정

**Algorithm 1** Per-slot assignment of CAST

**Input:** cap$_r$, $\rho_r$, $H$, $M_A$, $M_B$, $\varepsilon$, $\mathcal{A}$ = {0, 0.1, …, 1}, forecasts $\hat{C}_r^{(t)}(\cdot)$, job stream
**Output:** ($r(j)$, $\tau_j$) for all $j$

$Q \leftarrow \emptyset$
for $t \leftarrow$ 0, 1, 2, … do
  for each $j$ with $\lfloor s_j \rfloor = t$ do $Q \leftarrow Q \cup \{j\}$
  for each $j \in Q$ do
    $h_j \leftarrow \lfloor \min(D_j - d_j,\ t+H) - t \rfloor$
    if $j$ is non-deferrable or $(D_j - d_j) - t < 1$ then $h_j \leftarrow 0$
  for each $\alpha \in \mathcal{A}$ do
    $x^\alpha \leftarrow$ LP solution of (6), (7), (9), (10)
    $(\tilde{\lambda}_\alpha, \tilde{e}_\alpha) \leftarrow$ duration-weighted mean latency and forecast emissions of $x^\alpha$
  $\alpha^* \leftarrow$ knee point by (11) among the candidates with minimum excess over the ceiling; $x \leftarrow x^{\alpha^*}$
  if $x$ is fractional then $x \leftarrow$ MILP solution at $\alpha^*$ (HiGHS, relative gap 0.01%)
  for each $(j, r)$ with $j \in Q$ and $x_{jr0} = 1$ do
    $r(j) \leftarrow r$; $\tau_j \leftarrow \max(t, s_j)$; add $[\tau_j, \tau_j + d_j)$ to the running set of $r$; $Q \leftarrow Q \setminus \{j\}$

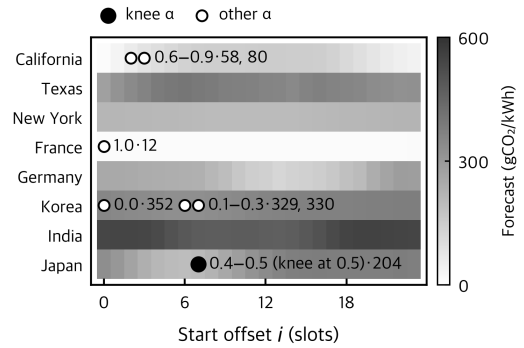



그림 3 한 작업에 대해 $\alpha$별로 선택된 리전과 시작 시각. 칸 옆 숫자는 $\alpha$의 범위와 예측 탄소집약도(gCO₂/kWh)다.
Fig. 3 Region and start slot chosen at each $\alpha$ for one job. Labels give the range of $\alpha$ and the forecast carbon intensity (gCO₂/kWh).

그림 3은 한국에서 제출된 작업 하나의 후보 격자와 $\alpha$에 따라 선택된 칸을 보인다. $\alpha$가 0이면 한국에서 즉시 시작하고, 0.1~0.3이면 한국에서 6~7시간 연기한다. 0.4~0.5이면 일본에서 7시간 뒤에, 0.6~0.9이면 캘리포니아에서 2~3시간 뒤에, 1.0이면 프랑스에서 즉시 시작한다. $\alpha$에 따라 리전과 시작 시각이 함께 바뀐다.

### 3.6 가중치 규칙

$\alpha$는 슬롯마다 정한다. 후보 $\alpha$ 11개($\mathcal{A}$ = {0, 0.1, …, 1})마다 배정 문제를 풀고, 그 배정의 실행 시간 가중 평균 왕복 지연 시간 $\tilde{\lambda}_\alpha$와 예측 배출량 $\tilde{e}_\alpha$를 구한다. 두 값을 후보들 사이에서 0~1로 정규화하면 둘 다 가장 작은 이상점(ideal point)이 원점에 오며, 원점에 가장 가까운 후보를 고른다[30].

$$\alpha^* = \operatorname*{argmin}_{\alpha\in\mathcal{A}} \sqrt{\tilde{\lambda}_\alpha^2 + \tilde{e}_\alpha^2} \quad (11)$$

$\tilde{\lambda}_\alpha$와 $\tilde{e}_\alpha$는 정규화한 평균 지연과 예측 배출량이다. 이 규칙을 무릎점 규칙, 고른 점을 무릎점(knee point)이라 부른다. 상한을 넘기는 후보가 있으면 초과가 가장 작은 후보들 안에서 고르고, 거리가 같으면 작은 $\alpha$를, 모든 후보의 지연이나 배출량이 같으면 $\alpha$=1을 고른다. 그림 3의 슬롯에서 무릎점은 0.5다.

CAST는 두 가지로 운영할 수 있다. 하나는 슬롯마다 무릎점 규칙으로 $\alpha$를 고르는 것이다. 다른 하나는 운영 첫 주에 무릎점 규칙을 적용해, 그 주와 같은 평균 지연을

내는 고정 $\alpha$를 정해 쓰는 것이다. 알고리즘 1은 무릎점 규칙을 쓸 때 한 슬롯의 처리 과정이다.